

# Introducción al Procesamiento de Lenguaje Natural (NLP)

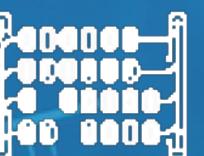
**Clase II:** Sistemas de Reconocimiento  
Automático de Voz (ASR) III. HMM

**Alexander Caicedo**



Universidad del  
**Rosario**

Escuela de Ingeniería,  
Ciencia y Tecnología

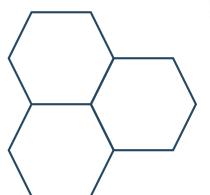
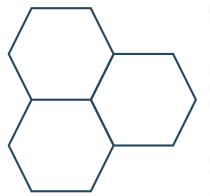


**MACC**  
Matemáticas Aplicadas y  
Ciencias de la Computación

# Contenido

HMM.

HMM para ASR systems.



# Propiedad de Markov

Restricción de los sistemas dinámicos donde el estado actual depende solamente del estado anterior, y no del historial de estados.

# Hidden Markov Models I

## HMM Clásico con observaciones deterministas

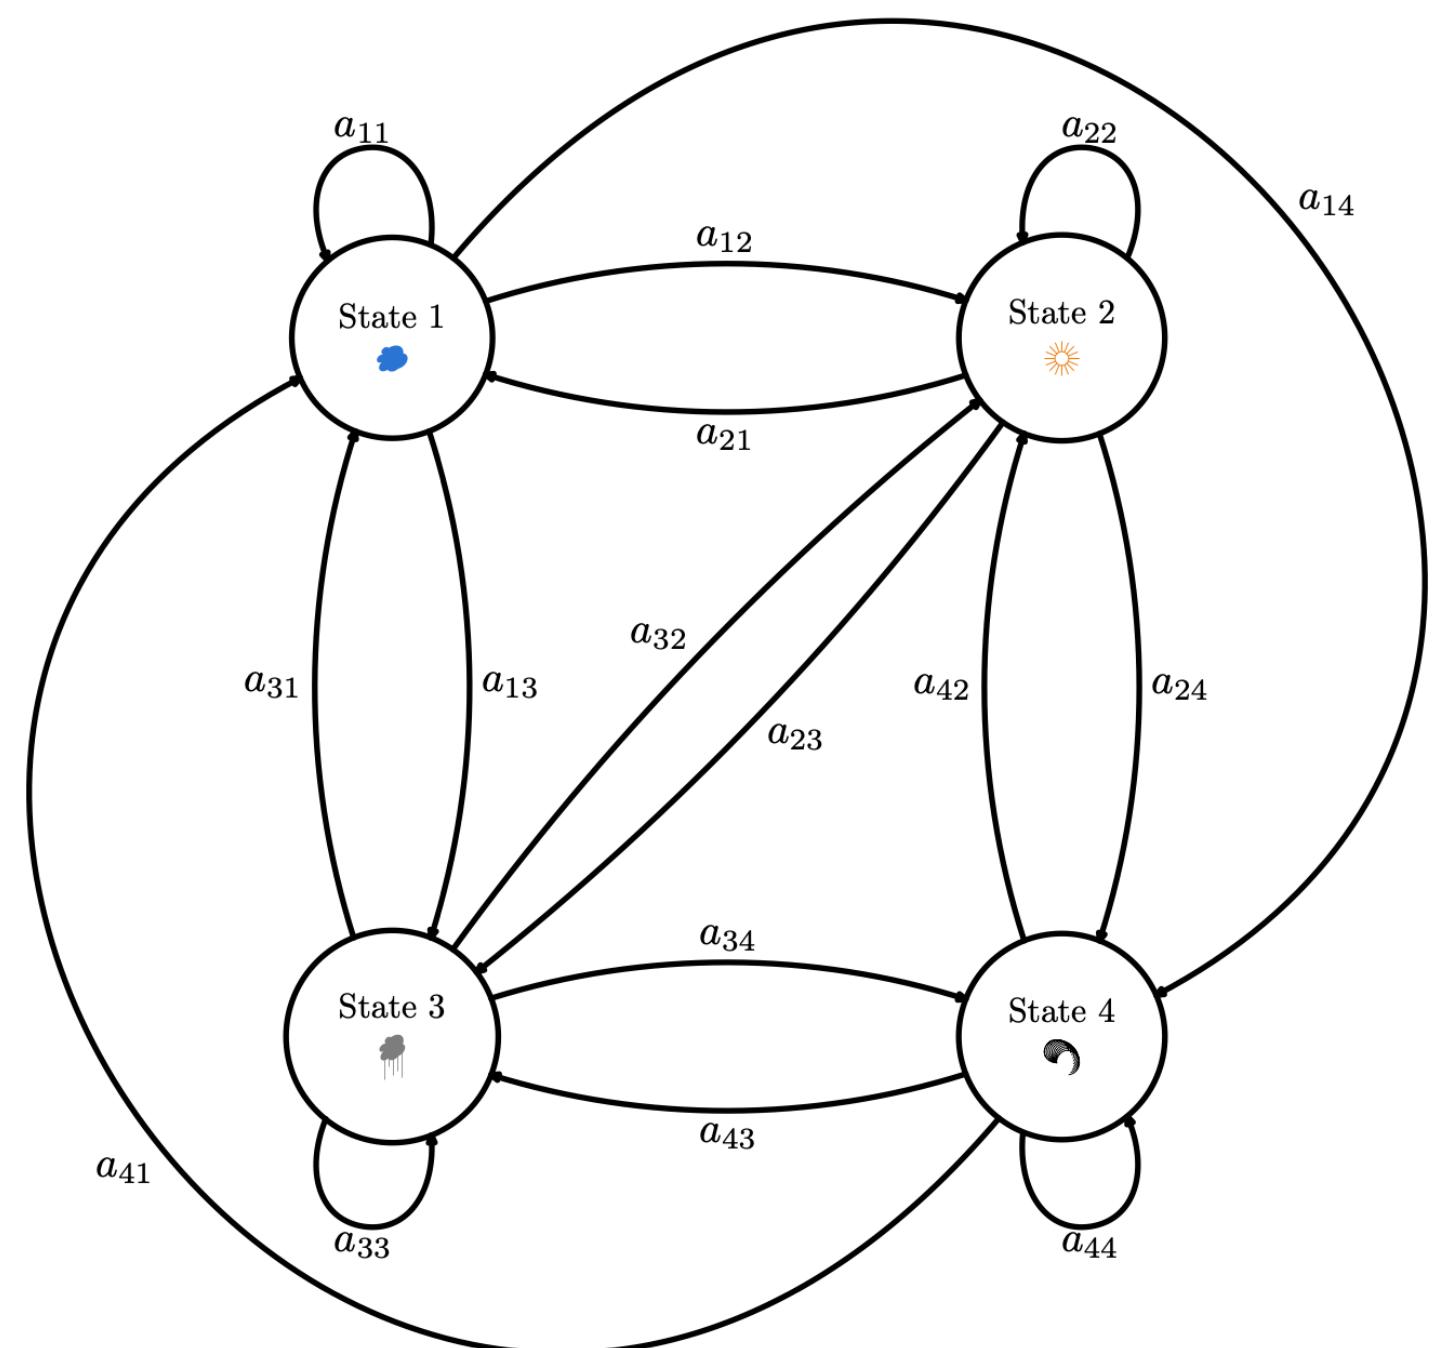


Figure 4.1: Markov model of the weather

- **State 1:** cloudy
- **State 2:** sunny
- **State 3:** rainy
- **State 4:** windy

Probabilidades de Transición

$$a_{ij} \geq 0 \quad \forall j, i$$
$$\sum_{j=1}^N a_{ij} = 1 \quad \forall i$$

Matrix de Transición de Probabilidades

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1N} \\ a_{21} & a_{22} & \dots & a_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ a_{N1} & a_{N2} & \dots & a_{NN} \end{bmatrix}_{N \times N}$$

Distribución Inicial de los estados

$$\boldsymbol{\pi} = \begin{bmatrix} \pi_1 = P(q_1 = 1) \\ \pi_2 = P(q_1 = 2) \\ \vdots \\ \pi_N = P(q_1 = N) \end{bmatrix}_{N \times 1}$$
$$\sum_{i=1}^N \pi_i = 1$$

Source: <https://www.diva-portal.org/smash/get/diva2:831263/FULLTEXT01.pdf>

# Hidden Markov Models II

HMM Clásico con observaciones deterministas

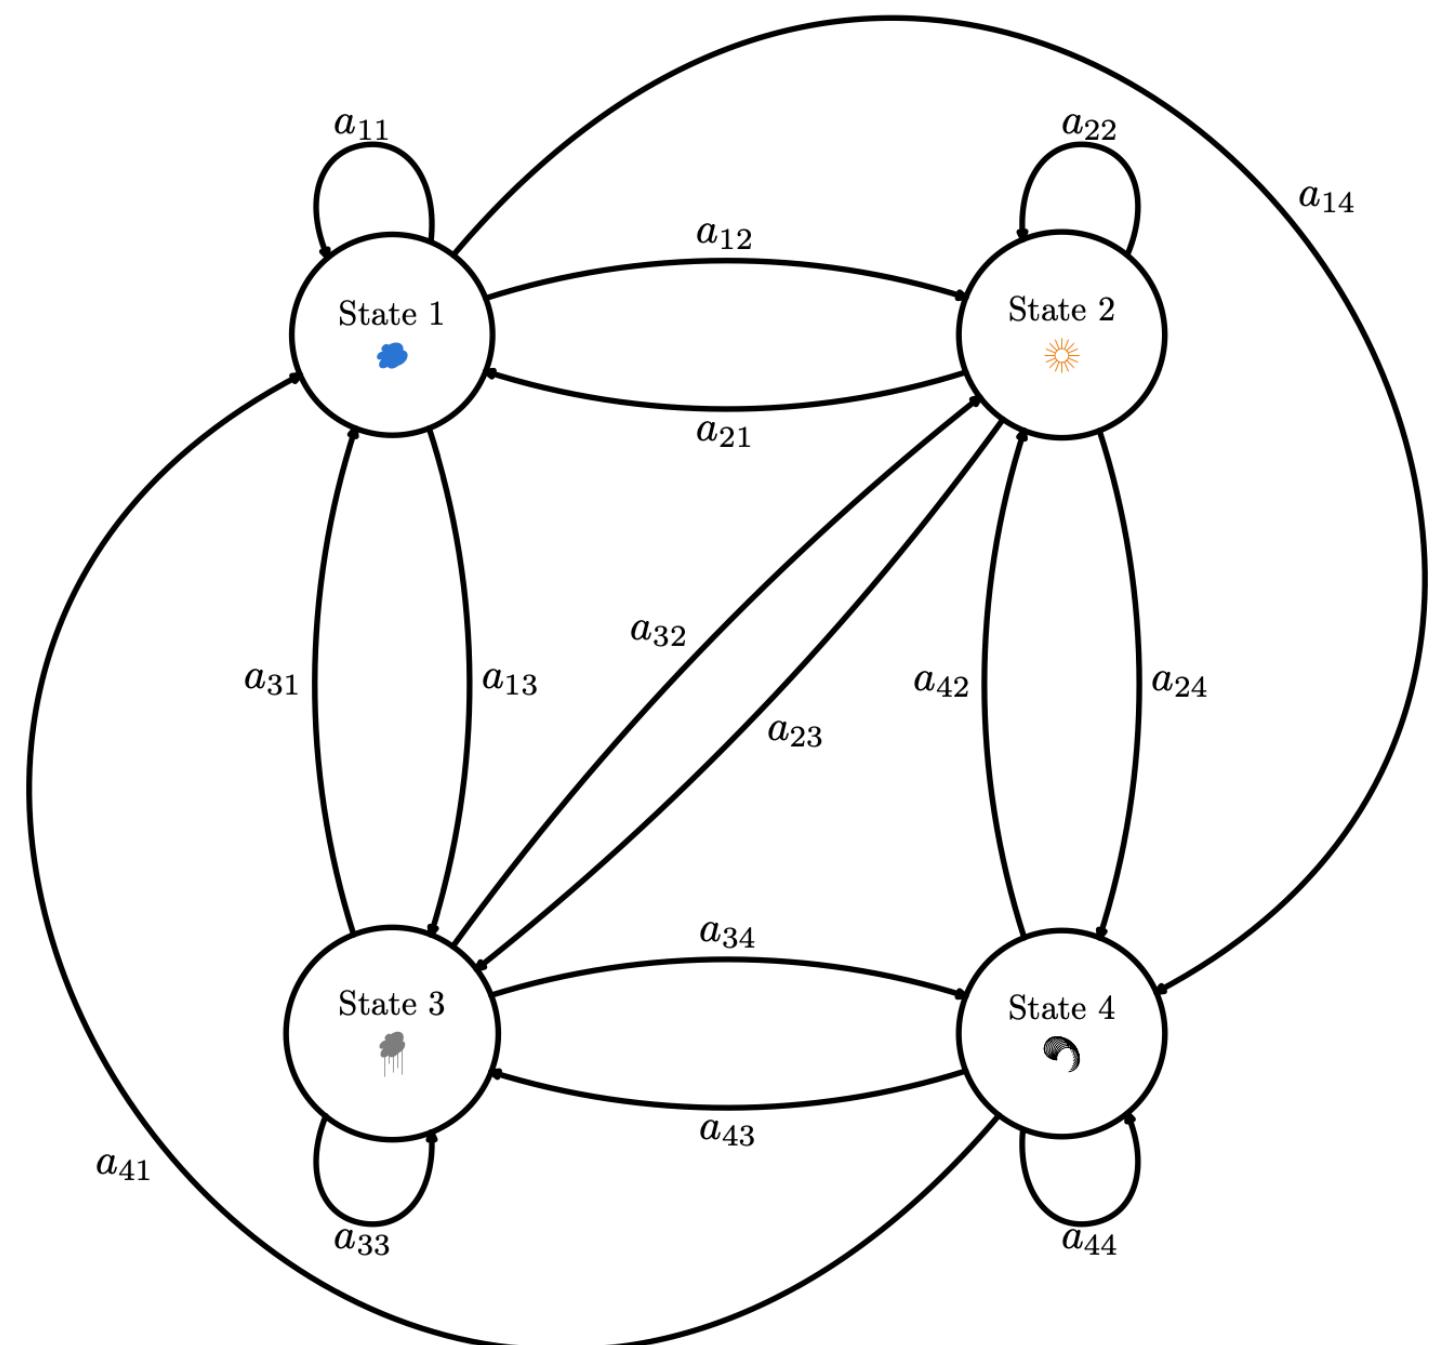


Figure 4.1: Markov model of the weather

En el modelo HMM propuesto, ¿cuál es la probabilidad de que la secuencia de eventos O ocurra?

$$\mathbf{O} = (\text{sunny, rainy, sunny, windy, cloudy, cloudy}) = (2, 3, 2, 4, 1, 1)$$

- **State 1:** cloudy
- **State 2:** sunny
- **State 3:** rainy
- **State 4:** windy

$$\begin{aligned} P(\mathbf{O}|\mathbf{A}, \boldsymbol{\pi}) &= P(2, 3, 2, 4, 1, 1|\mathbf{A}, \boldsymbol{\pi}) \\ &= P(2)P(3|2)P(2|3)P(4|2)P(1|4)P(1|1) \\ &= \pi_2 \cdot a_{23} \cdot a_{32} \cdot a_{24} \cdot a_{41} \cdot a_{11} \end{aligned}$$

Source: <https://www.diva-portal.org/smash/get/diva2:831263/FULLTEXT01.pdf>

# Hidden Markov Models III

¿Qué pasa si los estados ahora no son deterministicos sino probabilisticos?

Caracterización de la distribución de probabilidad de las observaciones

$$b_j(\mathbf{o}_t) = P(\mathbf{o}_t | q_t = j)$$

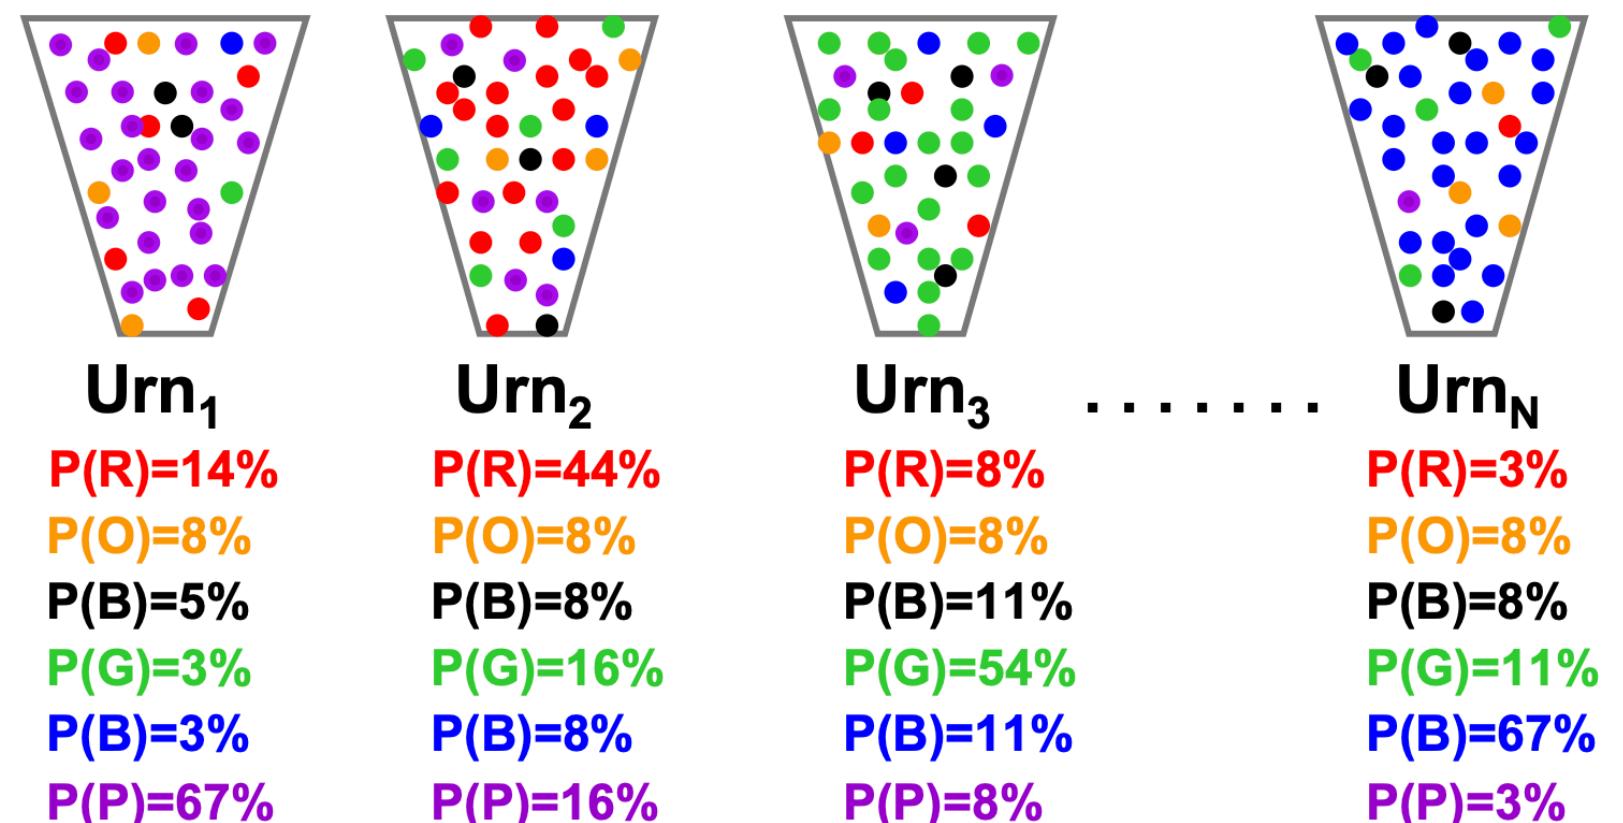


Figure 4.2: Urn and Ball example

¿Cómo el HMM genera observaciones?

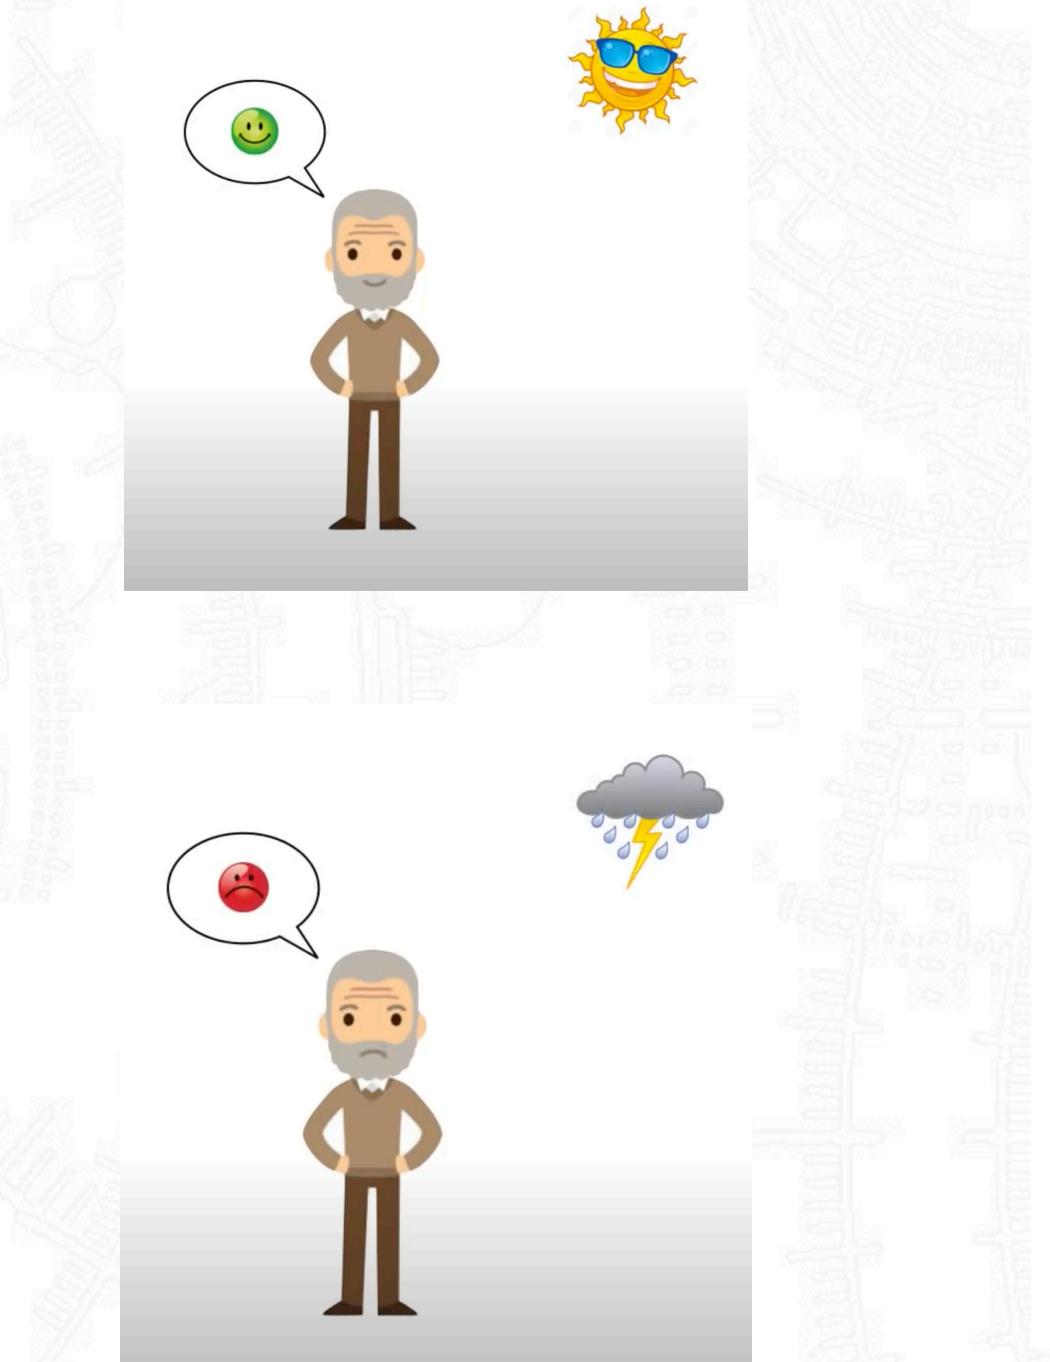
1. Escojo  $j$  un estado de acuerdo a la distribución a priori.
2. Defino  $t = 1; 1,2,3,\dots,T$
3. A partir de este estado escojo una observación a partir de su  $b_j(o_t)$
4. Me desplazo a otro estado , según la probabilidad de transición.
5. Defino  $t = t + 1$
6. Repito desde el paso 3, hasta terminar.

Source: <https://www.diva-portal.org/smash/get/diva2:831263/FULLTEXT01.pdf>

# Ejemplo



Alice quiere saber el clima, y ella sabe que el estado de animo de Bob se afecta pro el clima

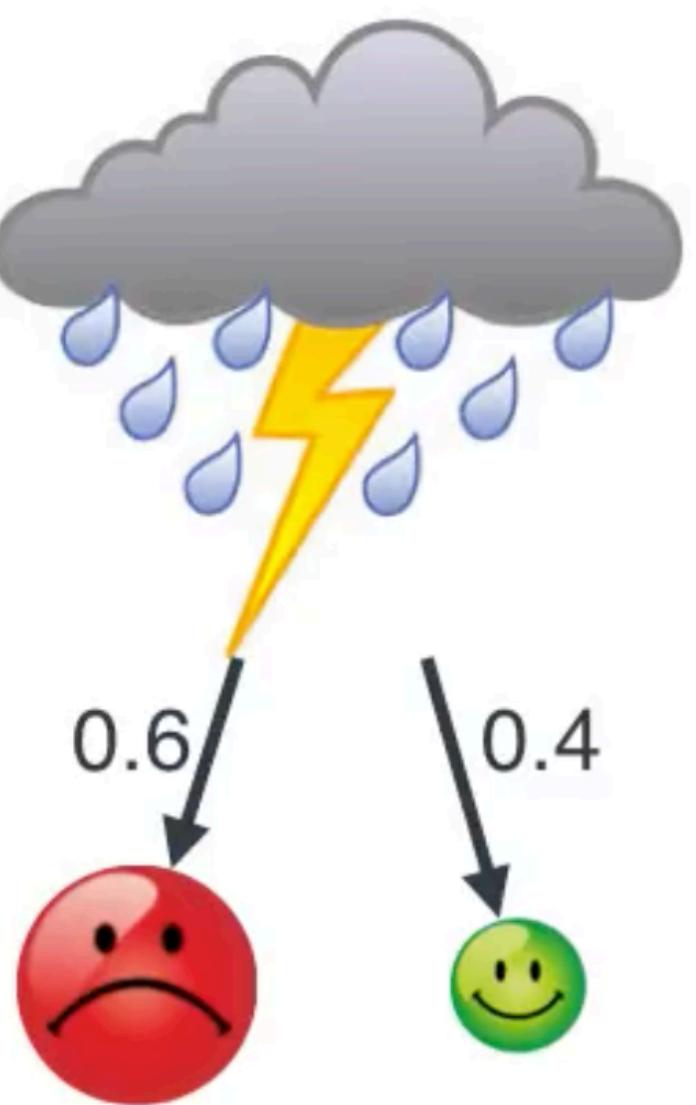
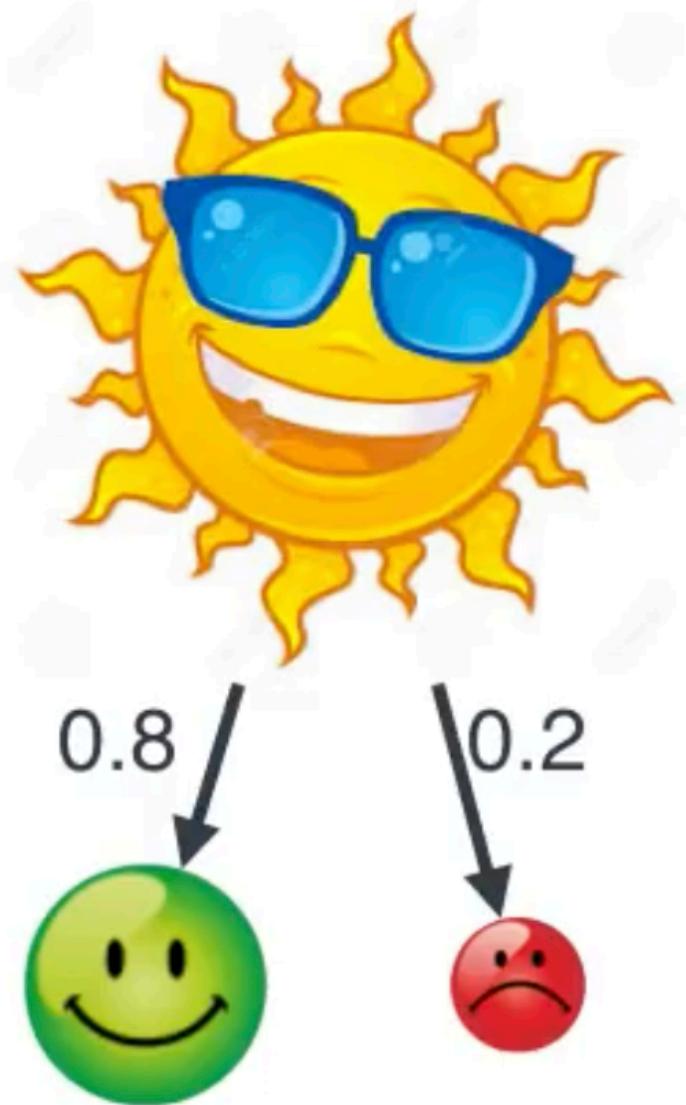


## Weather

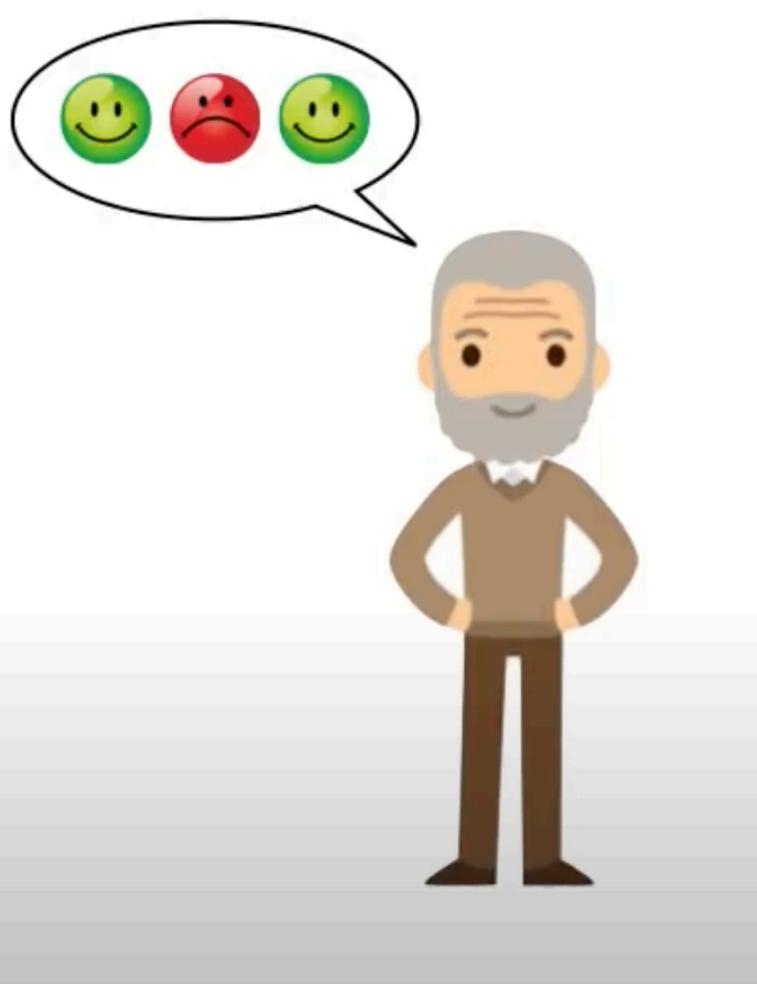
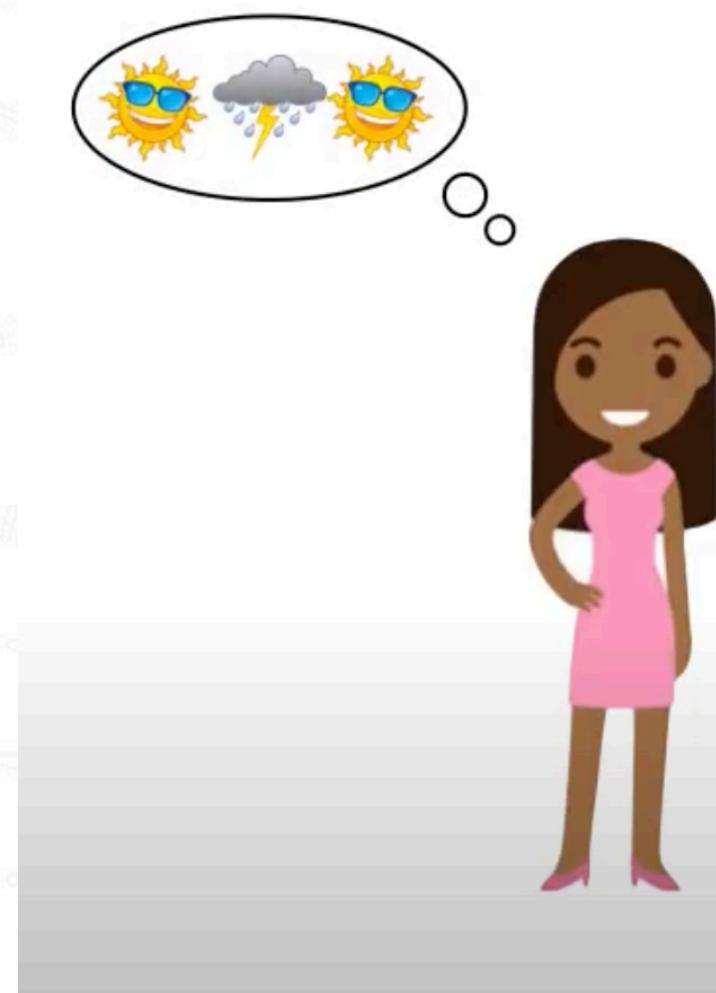


# Ejemplo

## Weather



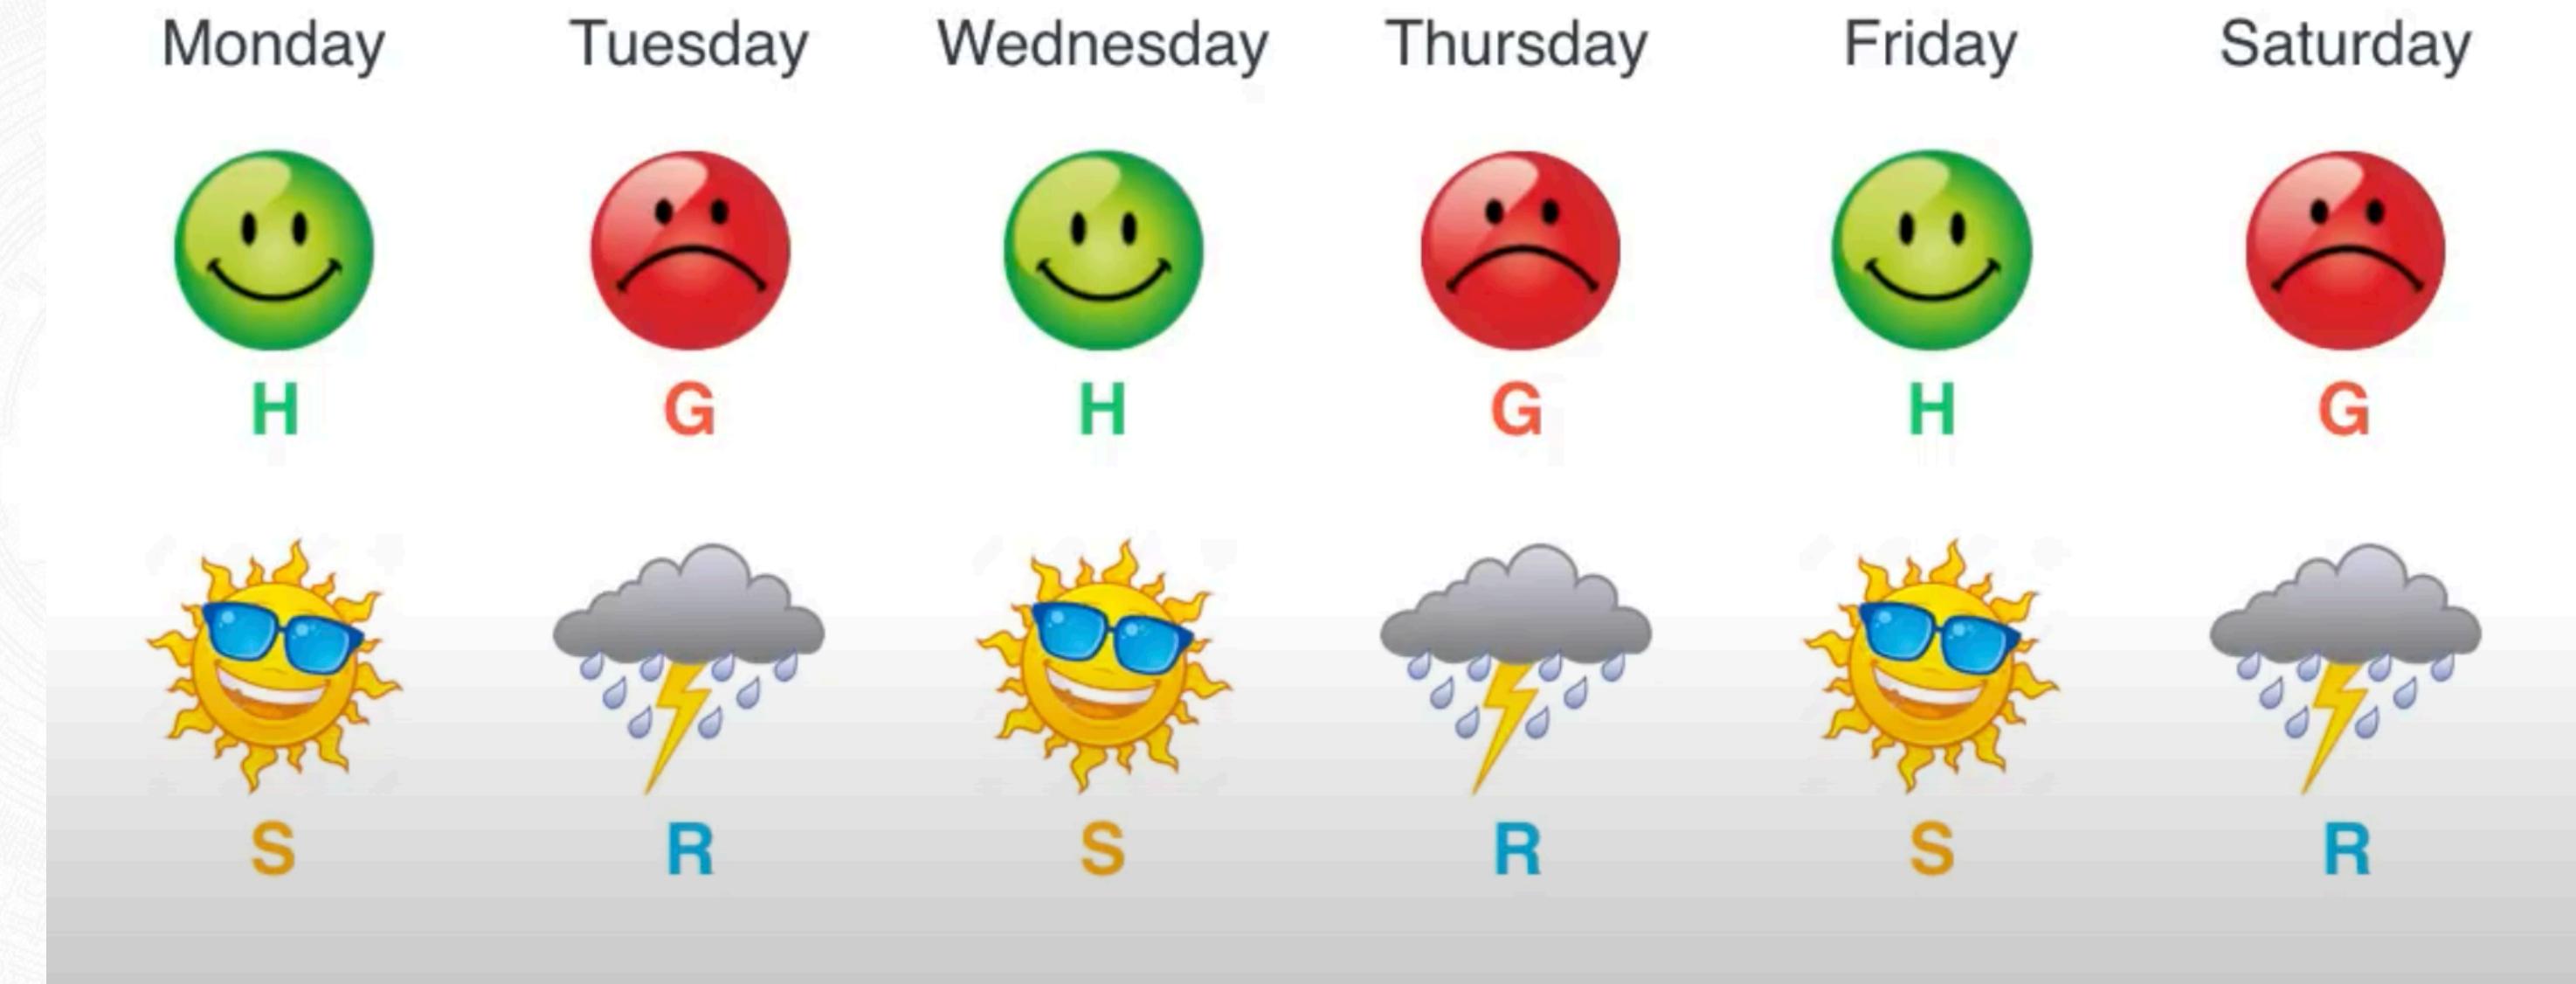
¿Qué sucede si el estado de Bob, aunque es afectado por el clima, no es determinístico?



Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

## Weather

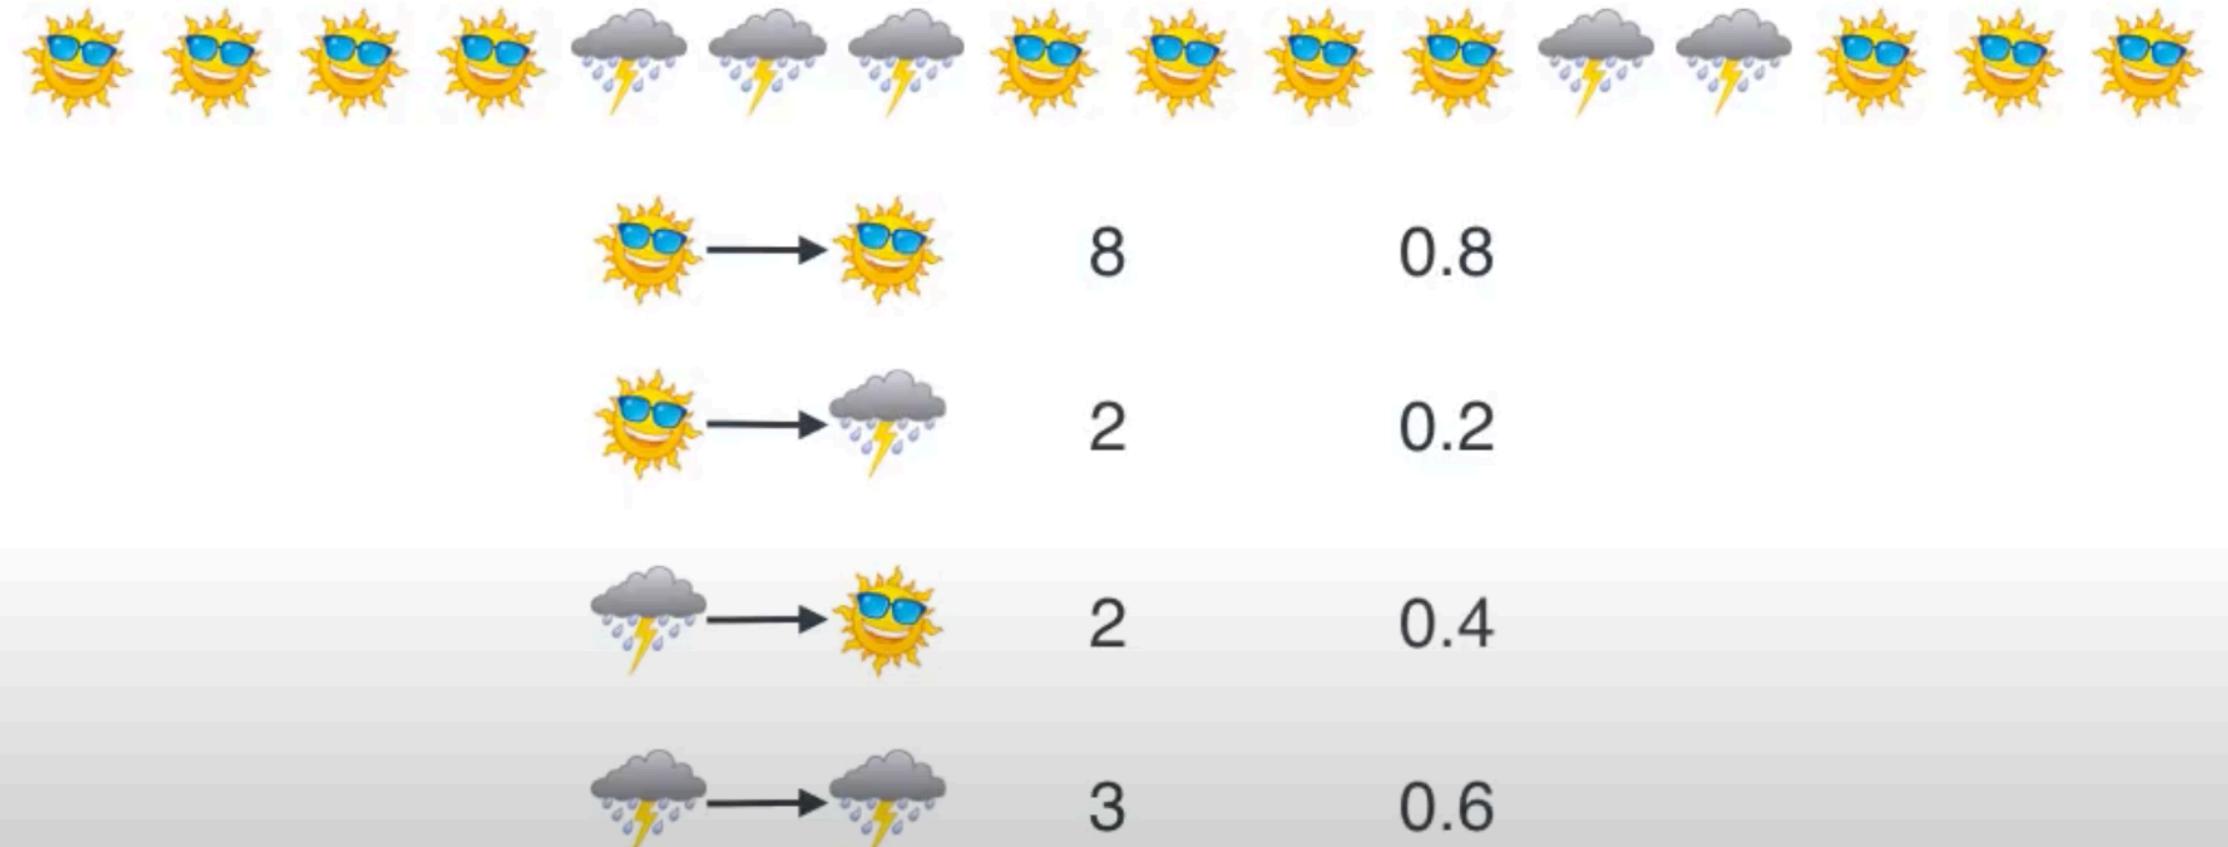


Ahora supongamos que Bob tuvo una semana un poco extraña, según su estado de ánimo.  
¿Es probable que el clima sea tan variable?

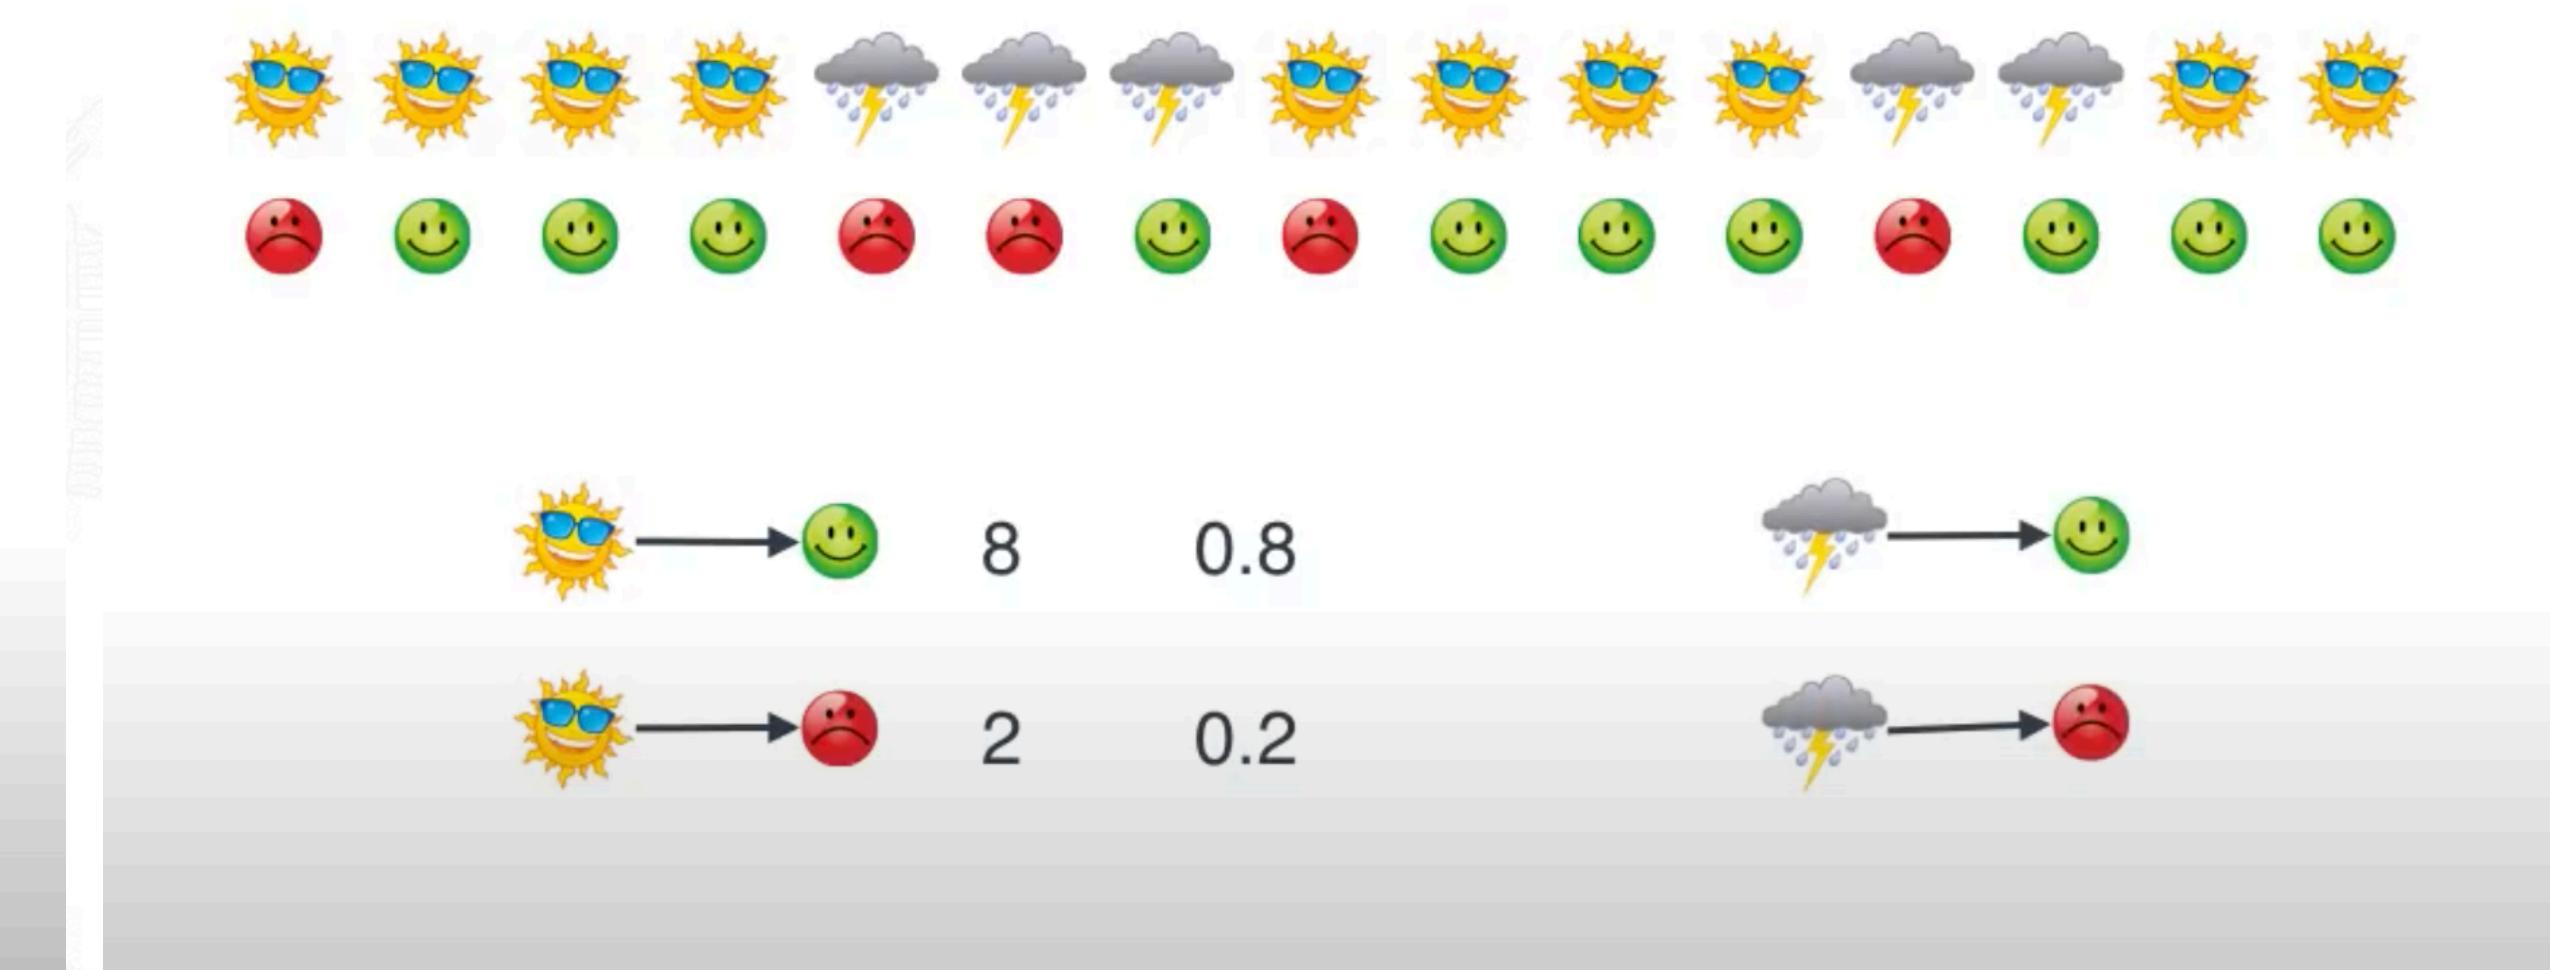
Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

How did we find the probabilities?



How did we find the probabilities?

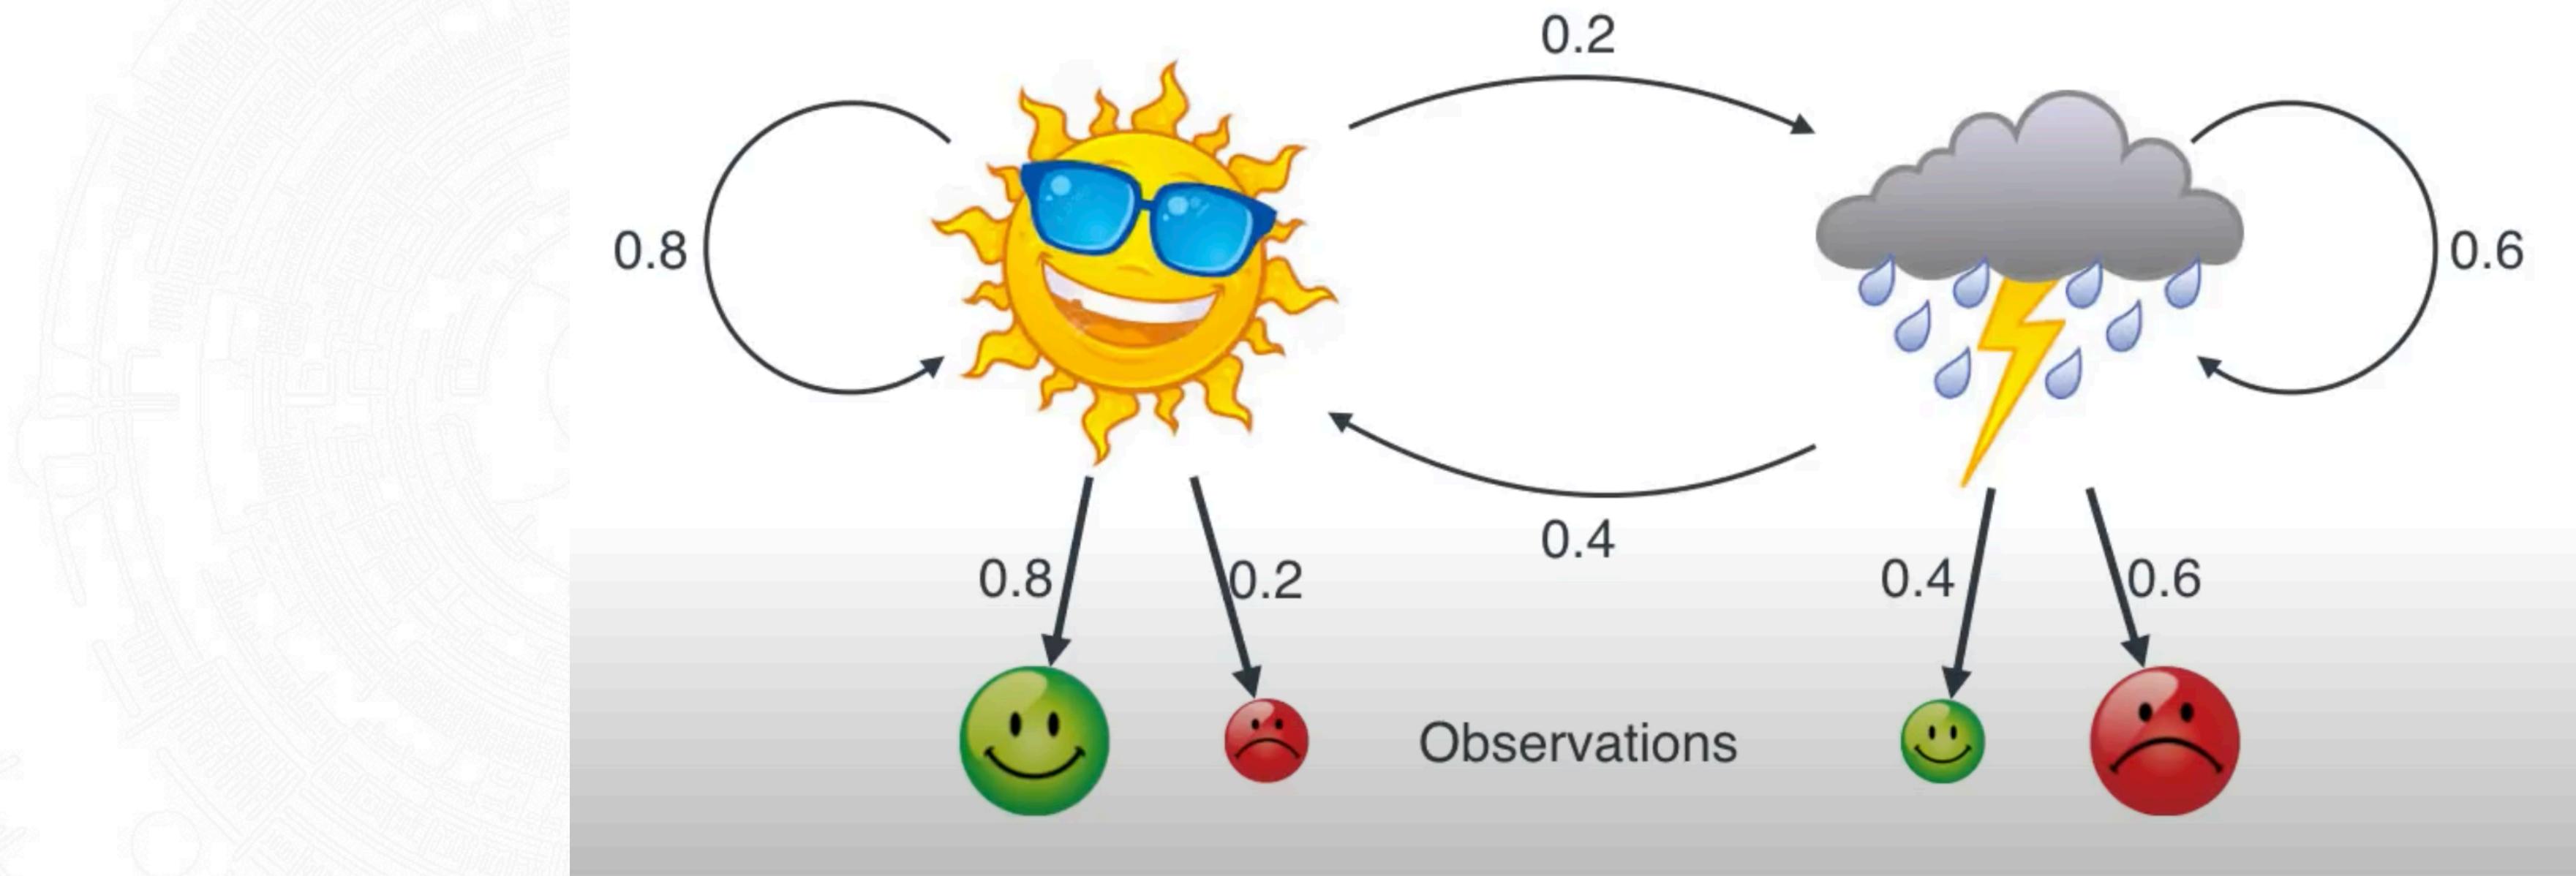


Supongamos que se tienen las siguientes observaciones

Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

## Hidden Markov Model

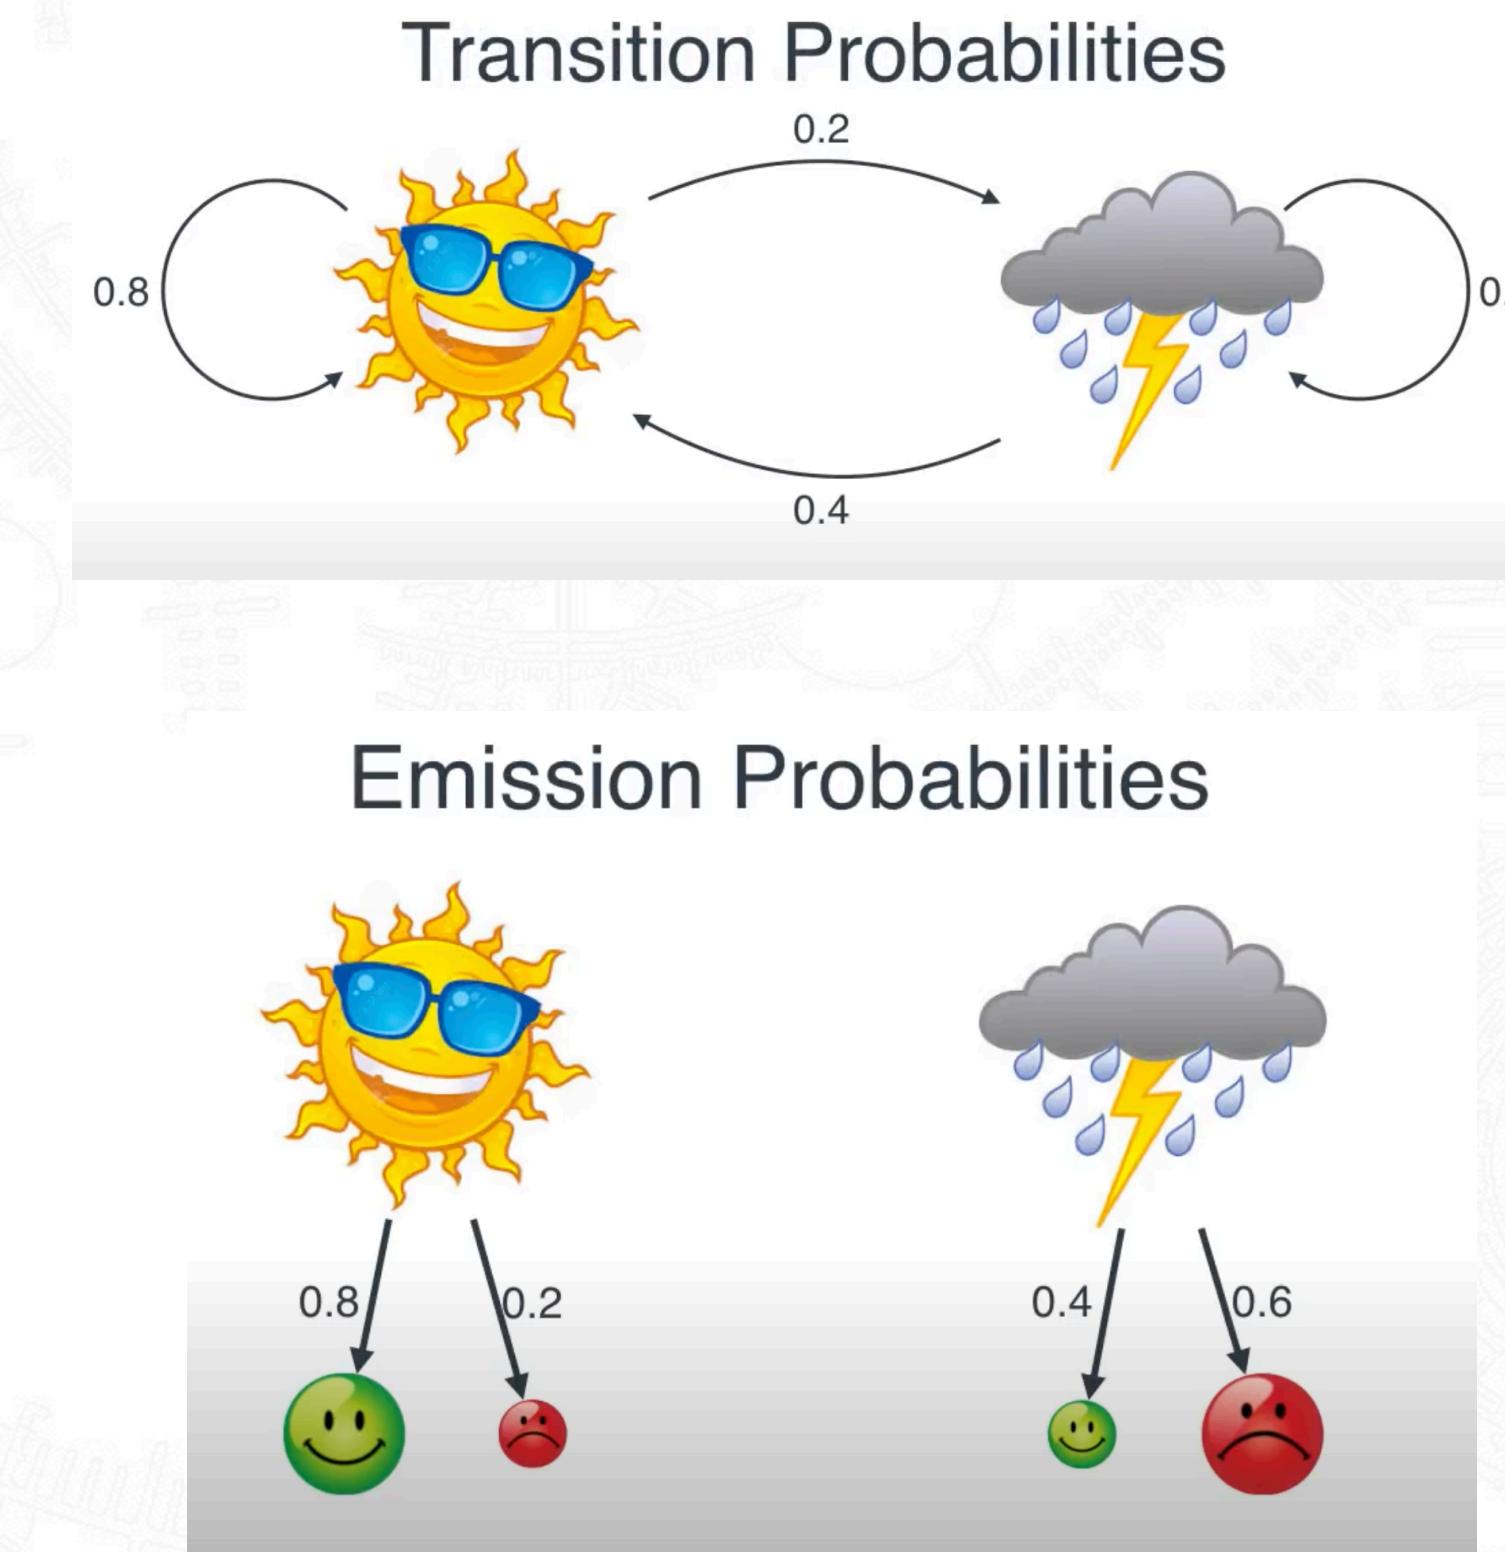
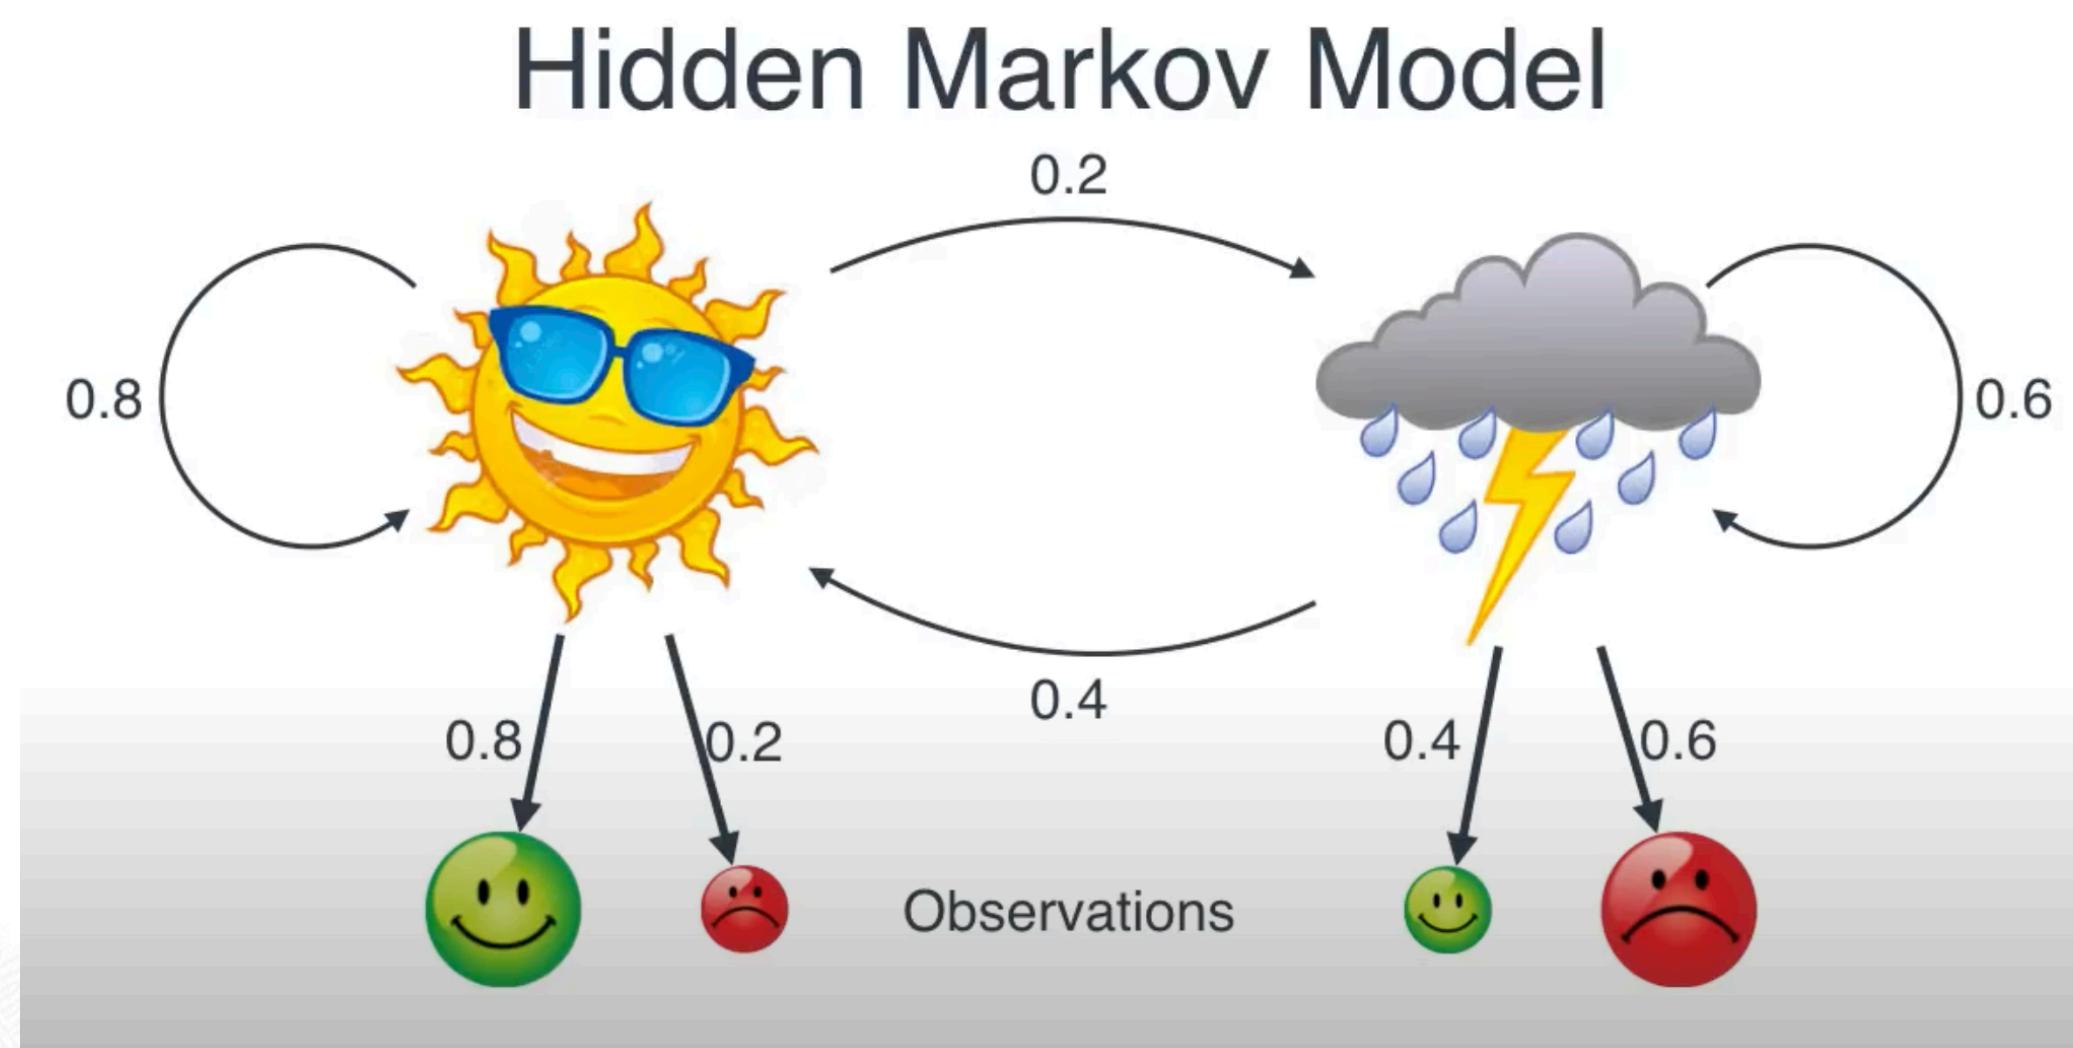


Con las probabilidades calculadas podemos postular el siguiente modelo oculto de Markov.

Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

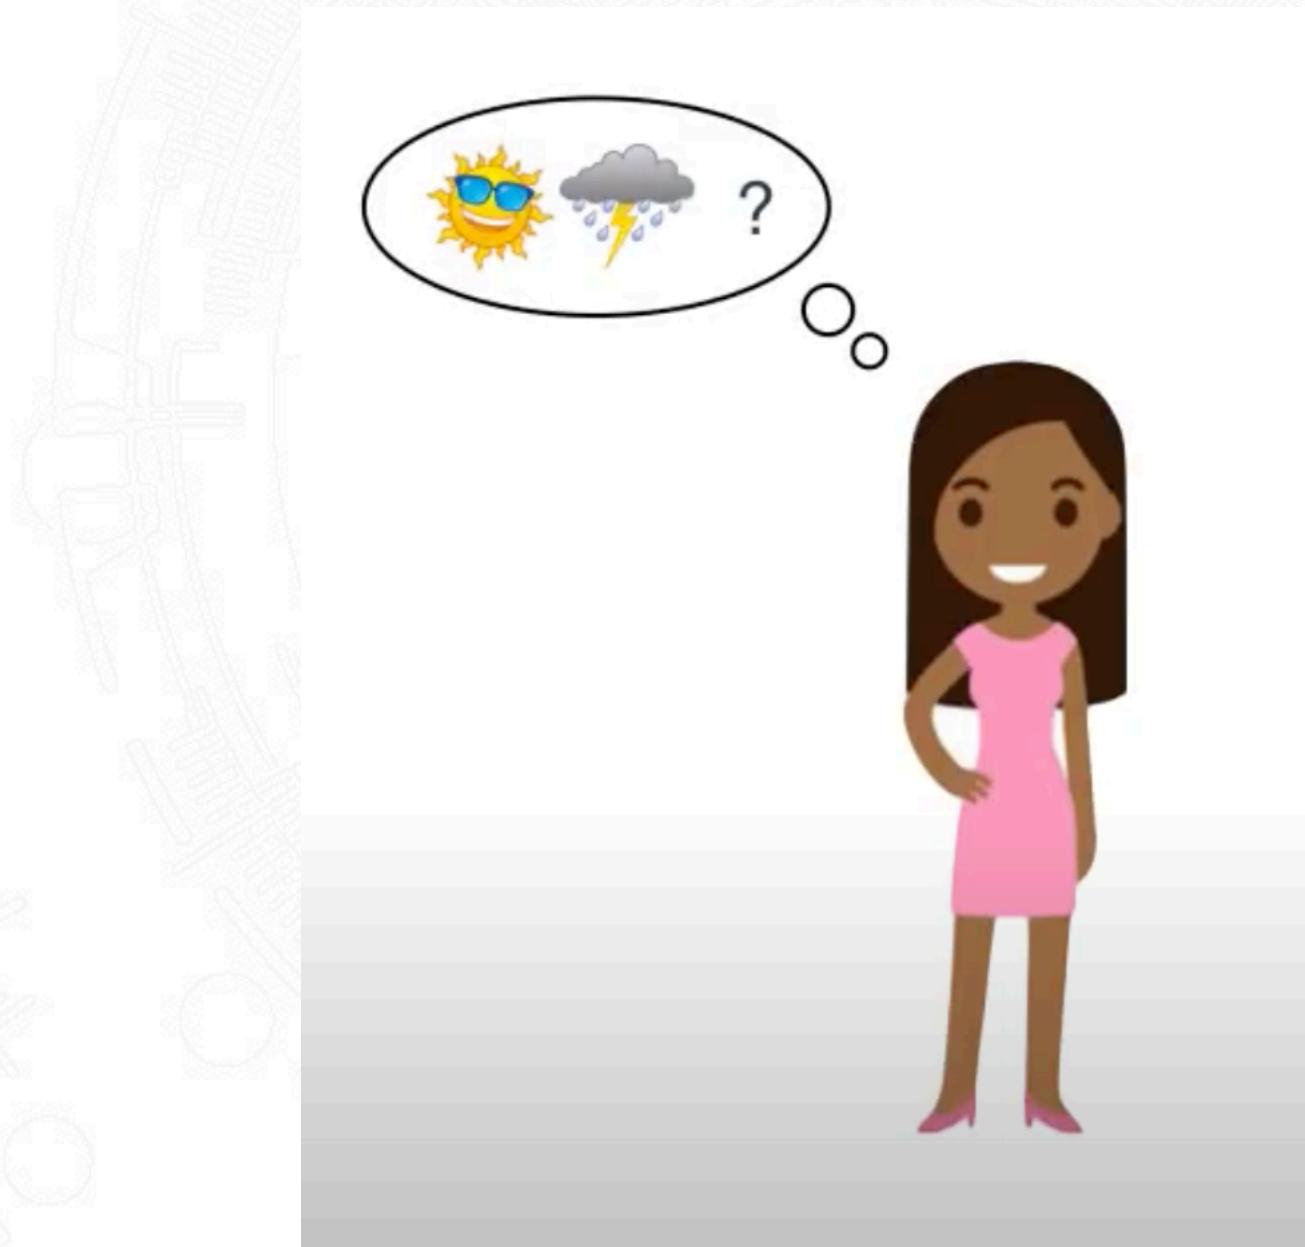
El modelo esta compuesto por las probabilidades de Transición y las de Emisión.



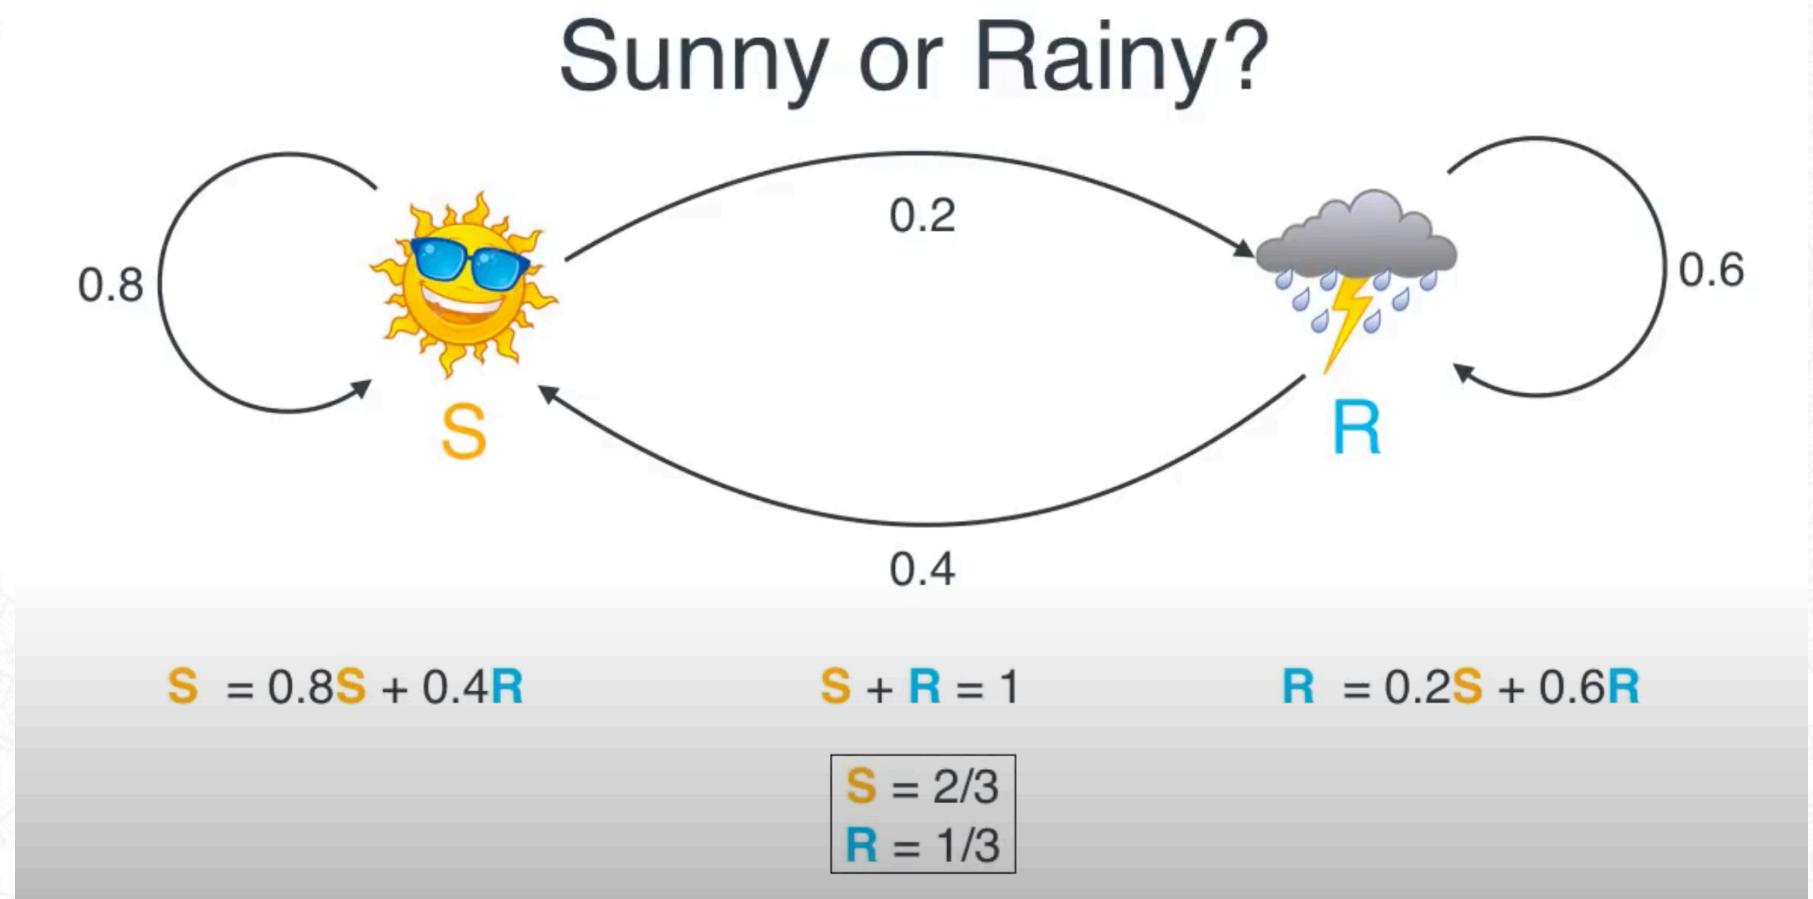
Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

Alice se pregunta, basado en el modelo, ¿cuál es la probabilidad de que sea un día soleado o un día lluvioso?



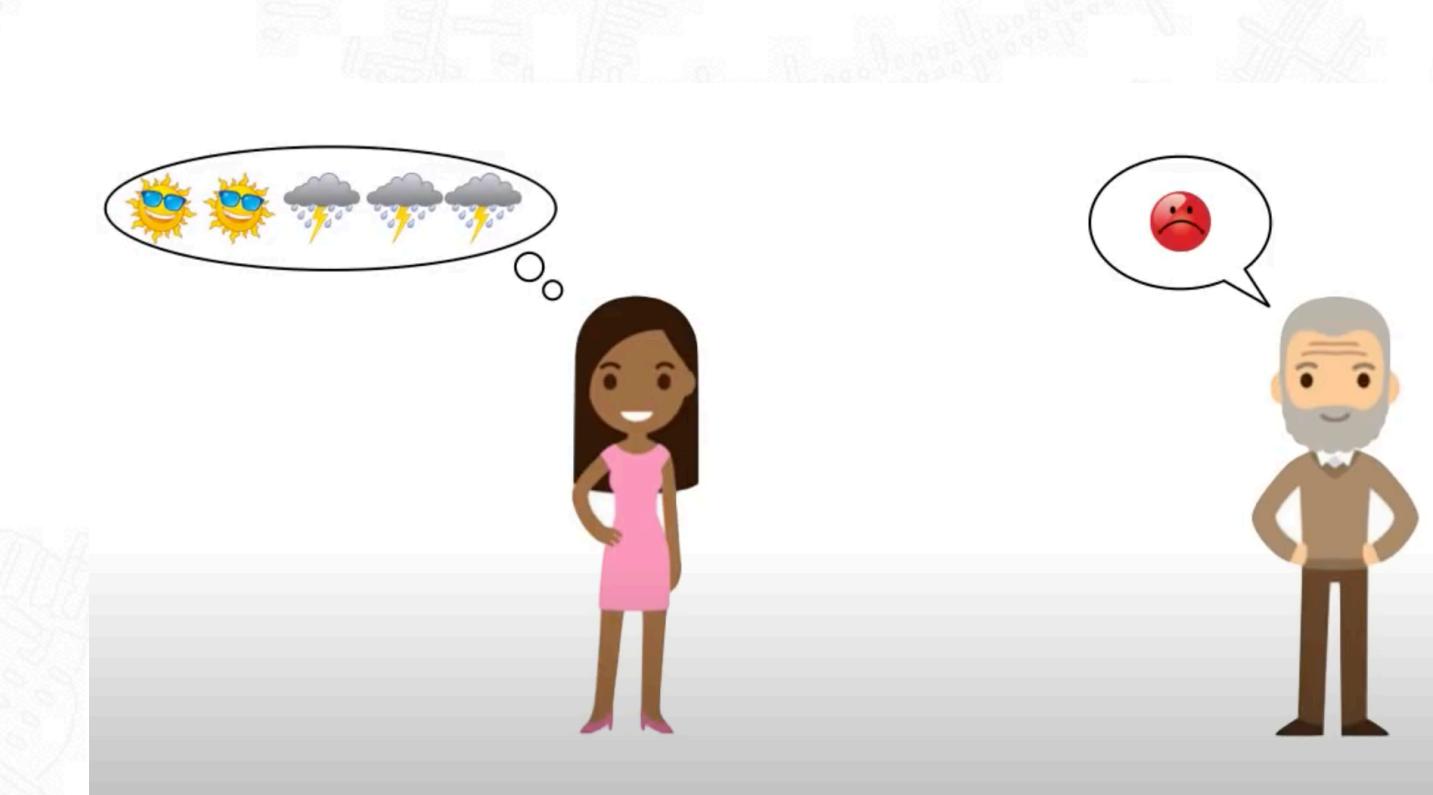
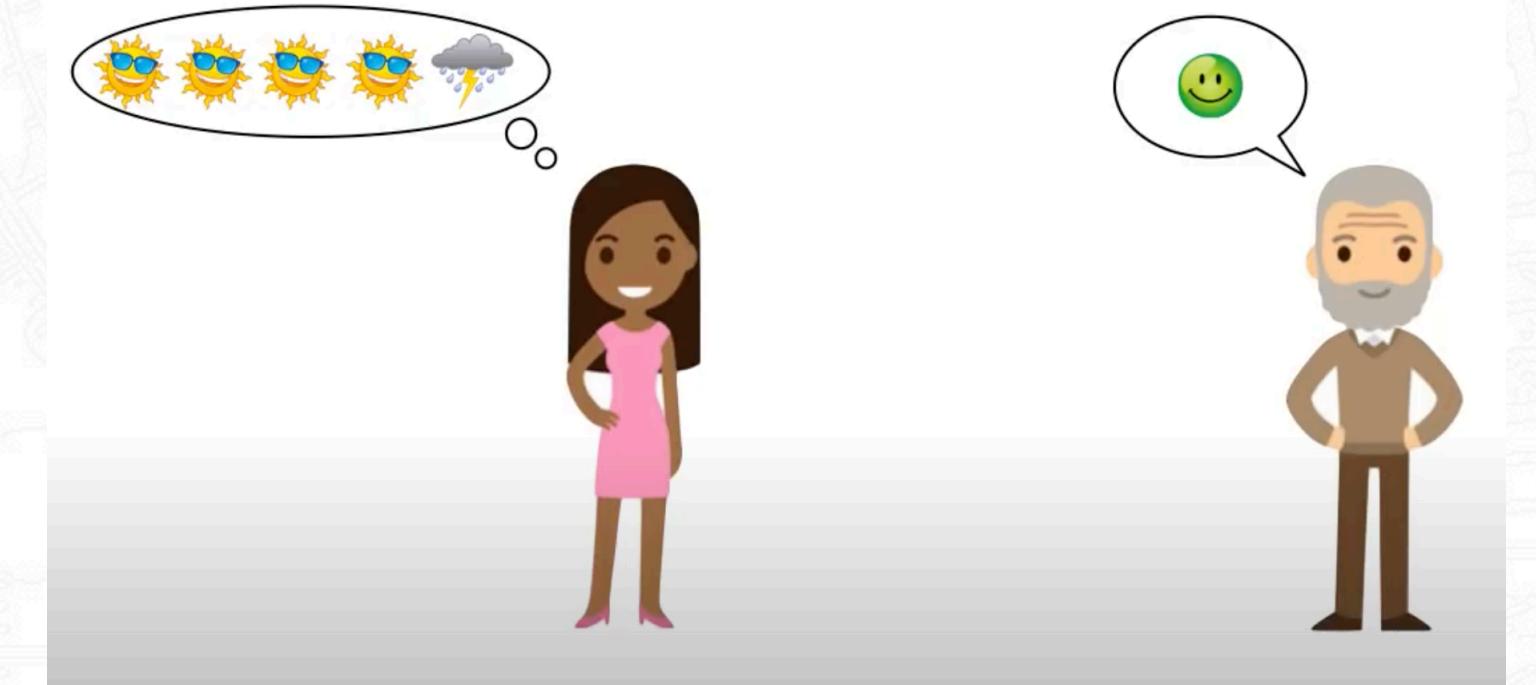
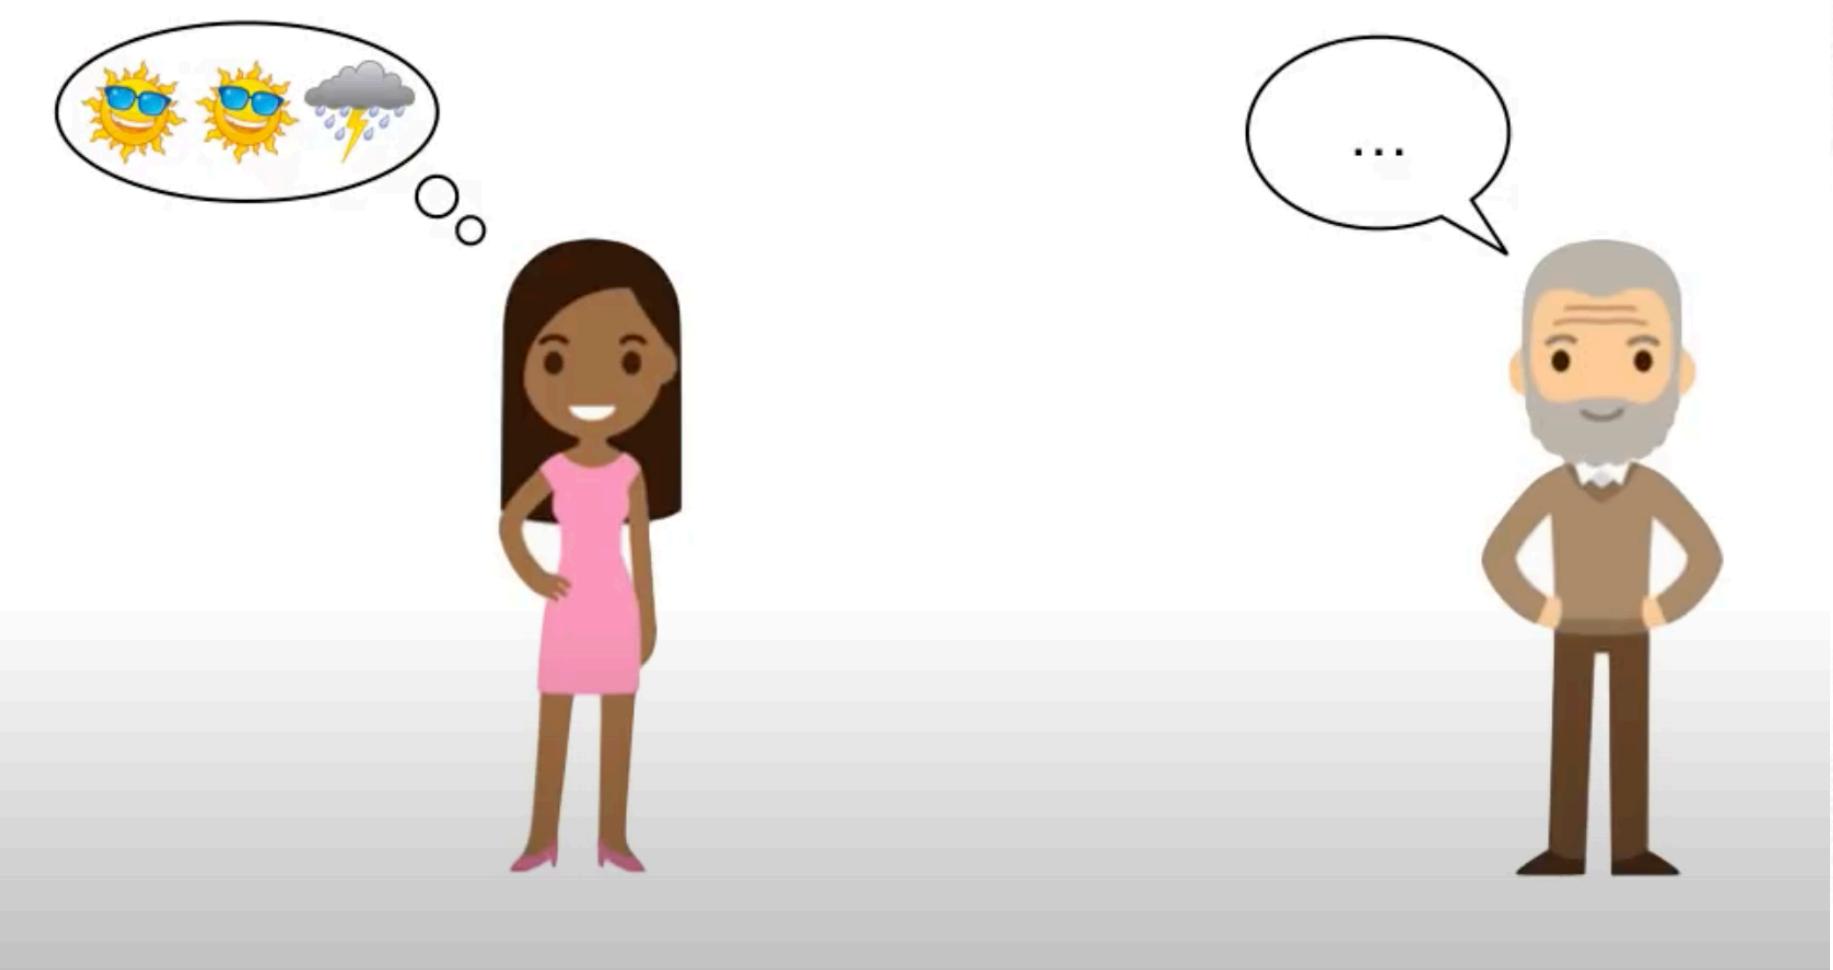
## How did we find the probabilities?



Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

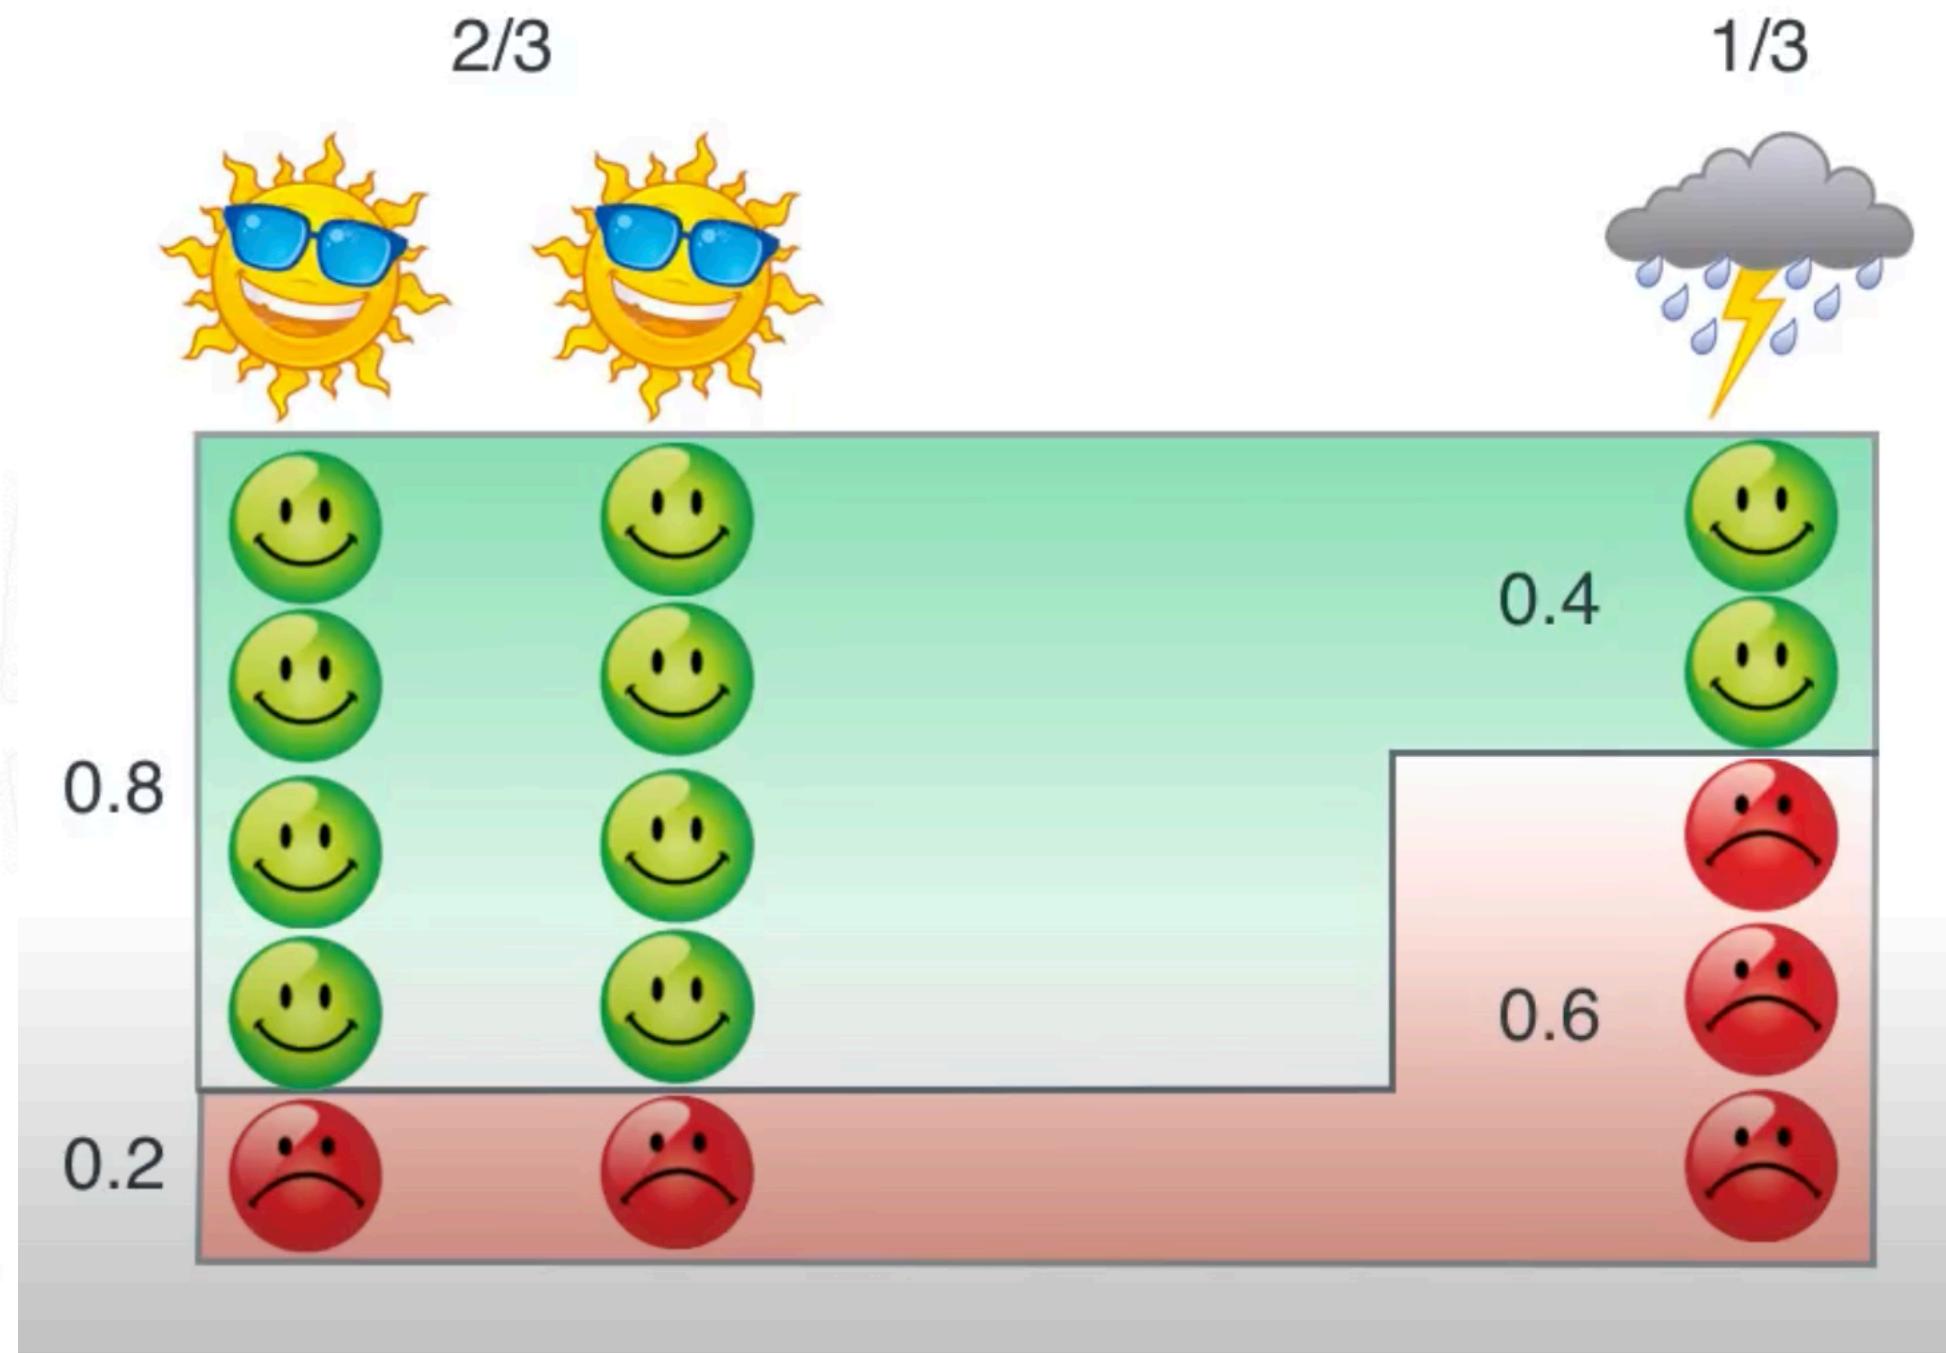
El prior de un estado es la probabilidad si no tenemos información extra. En este caso el estado de ánimo de Bob.



Al tener información sobre el estado de ánimo de Bob, las probabilidades cambian.

Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo



If ☺

$$P(\text{☀️} | \text{☺}) = \frac{8}{10}$$

$$P(\text{🌧️} | \text{☺}) = \frac{2}{10}$$

If ☹

$$P(\text{☀️} | \text{☹}) = \frac{2}{5}$$

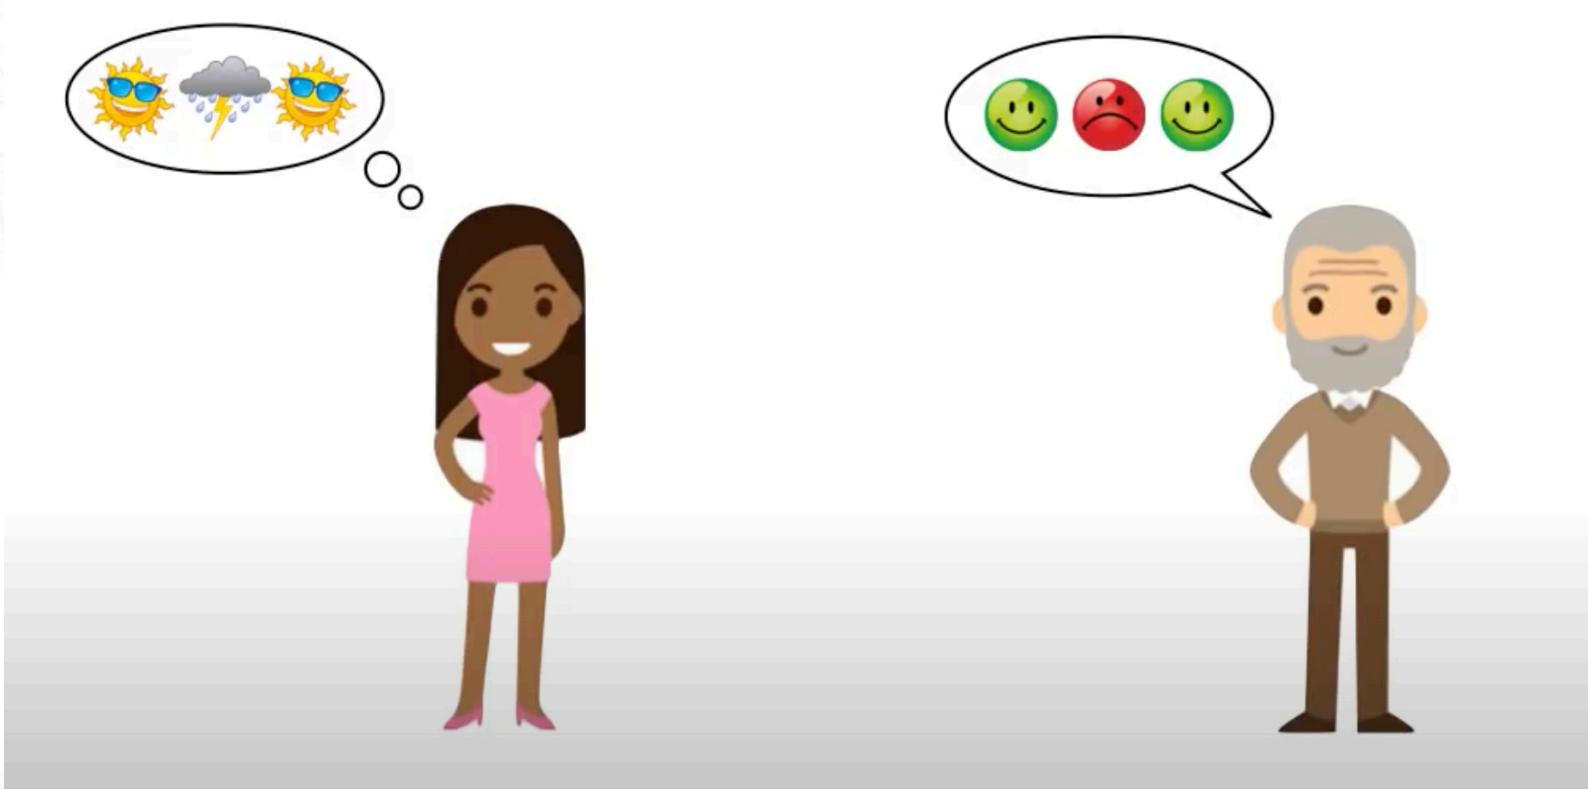
$$P(\text{🌧️} | \text{☹}) = \frac{3}{5}$$

Estas son las nuevas  
probabilidades condicionadas  
al estado de animo de Bob  
(Bayes Theorem)

Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

¿Cuál será la secuencia de estados del clima basados en las observaciones del estado del ánimo de Bob?



## If happy-grumpy, what's the weather?

Wednesday



H



S R

Thursday



G

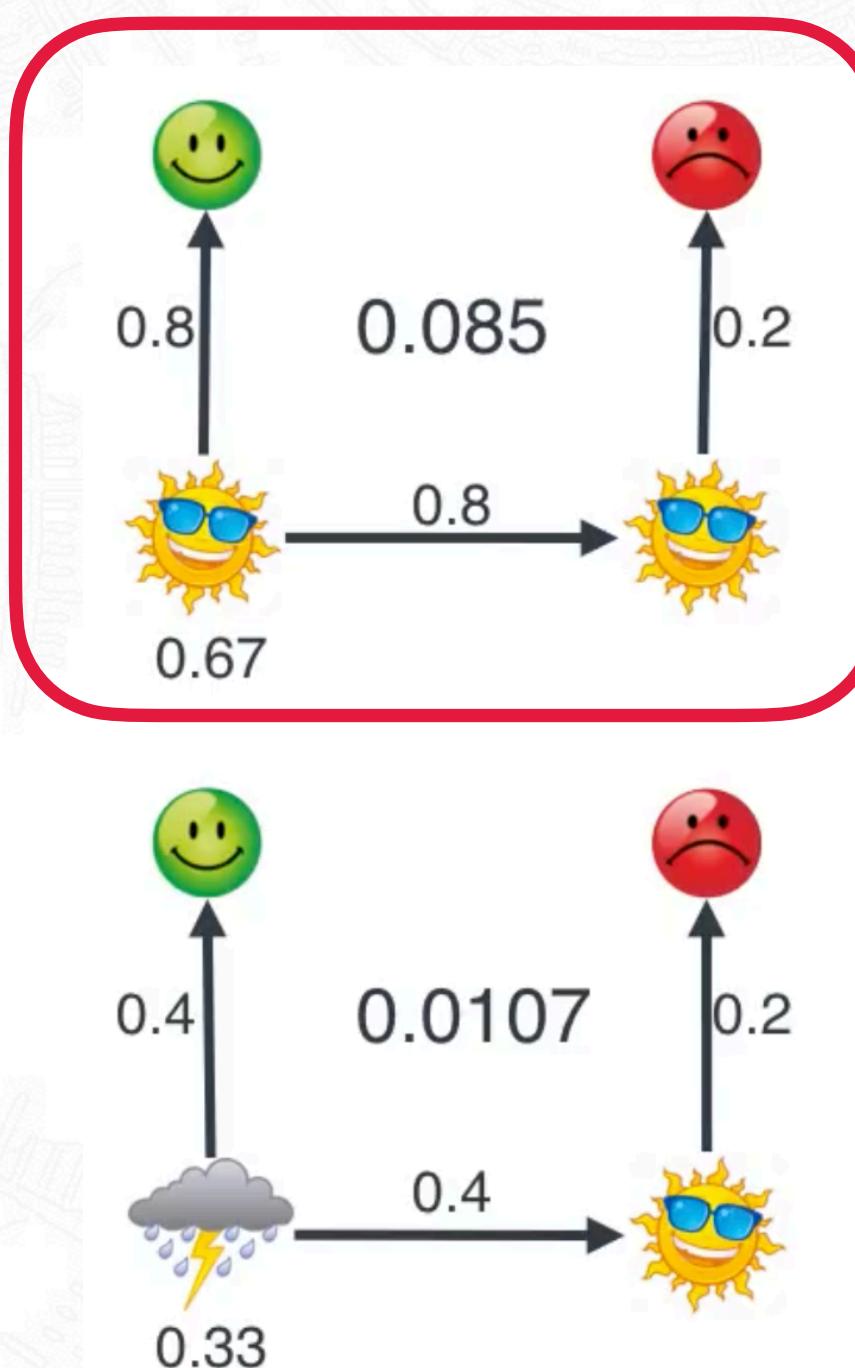
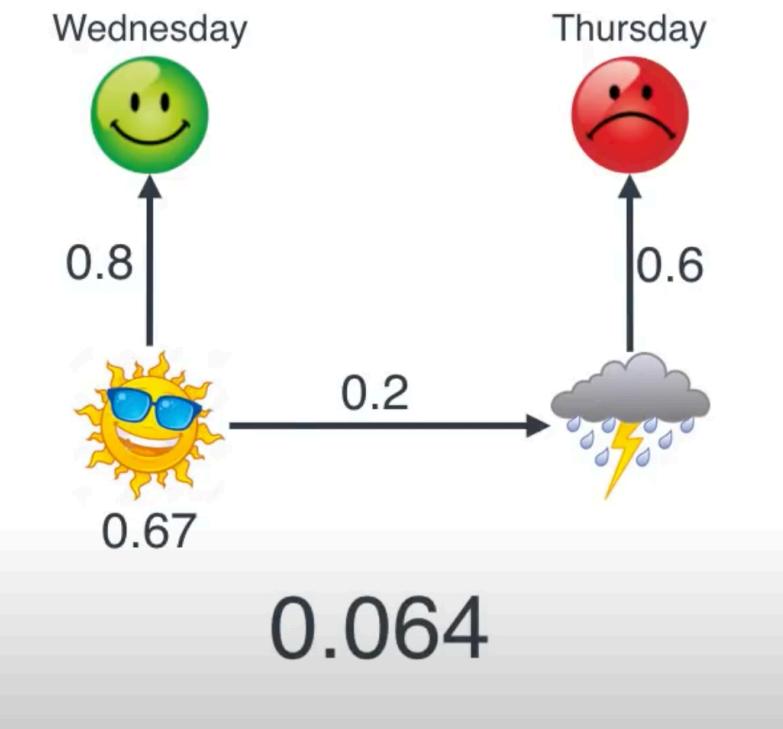
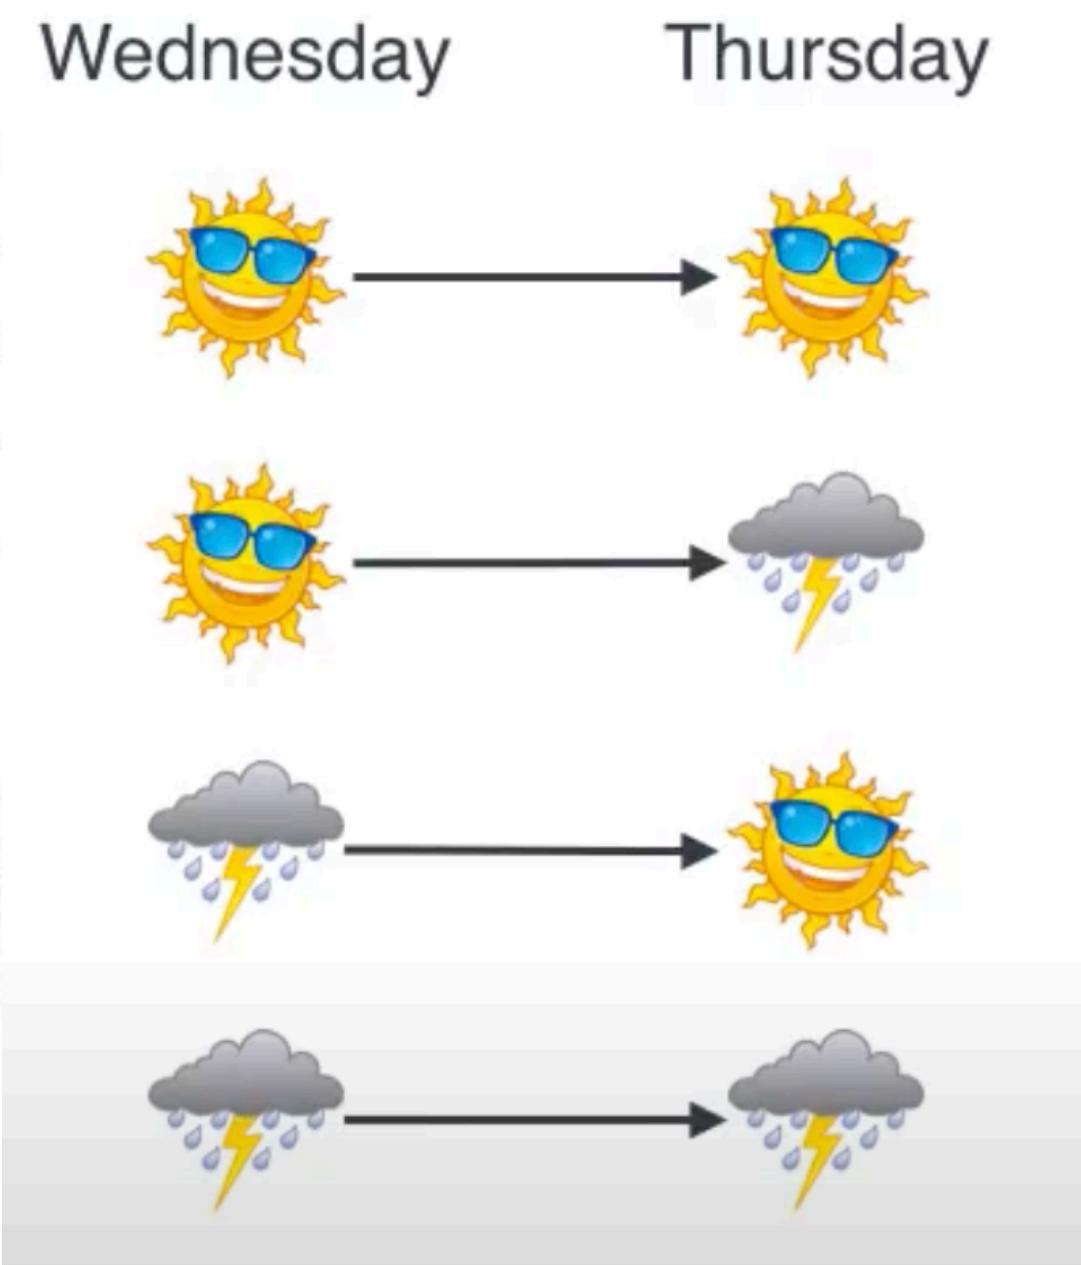


S R

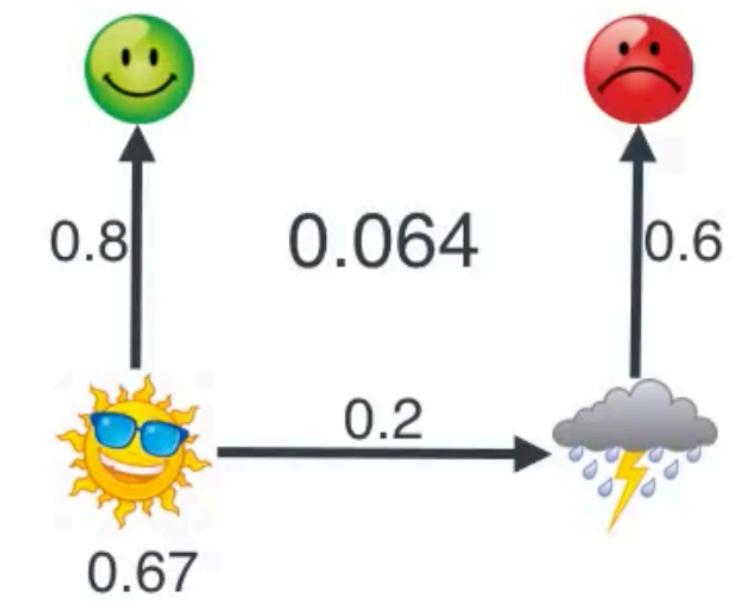
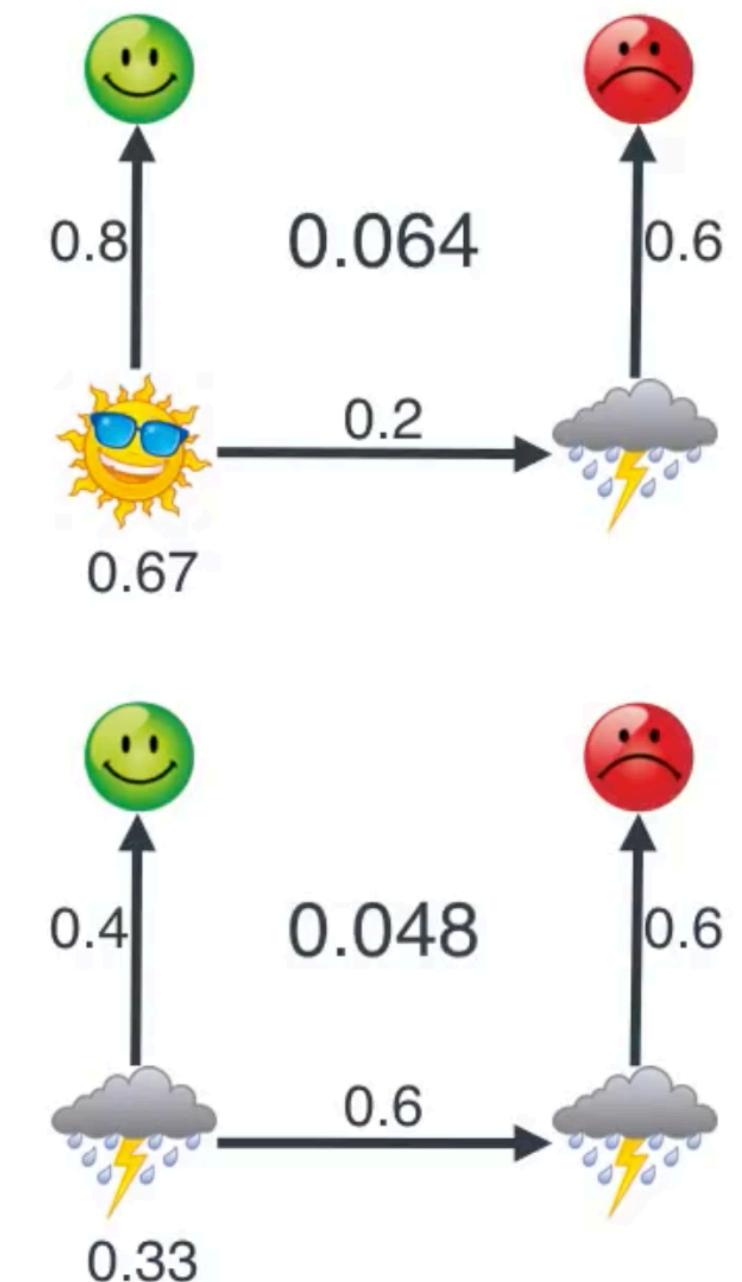
Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

Si solo queremos saber la secuencia del clima en dos días consecutivos, necesitamos evaluar 4 condiciones



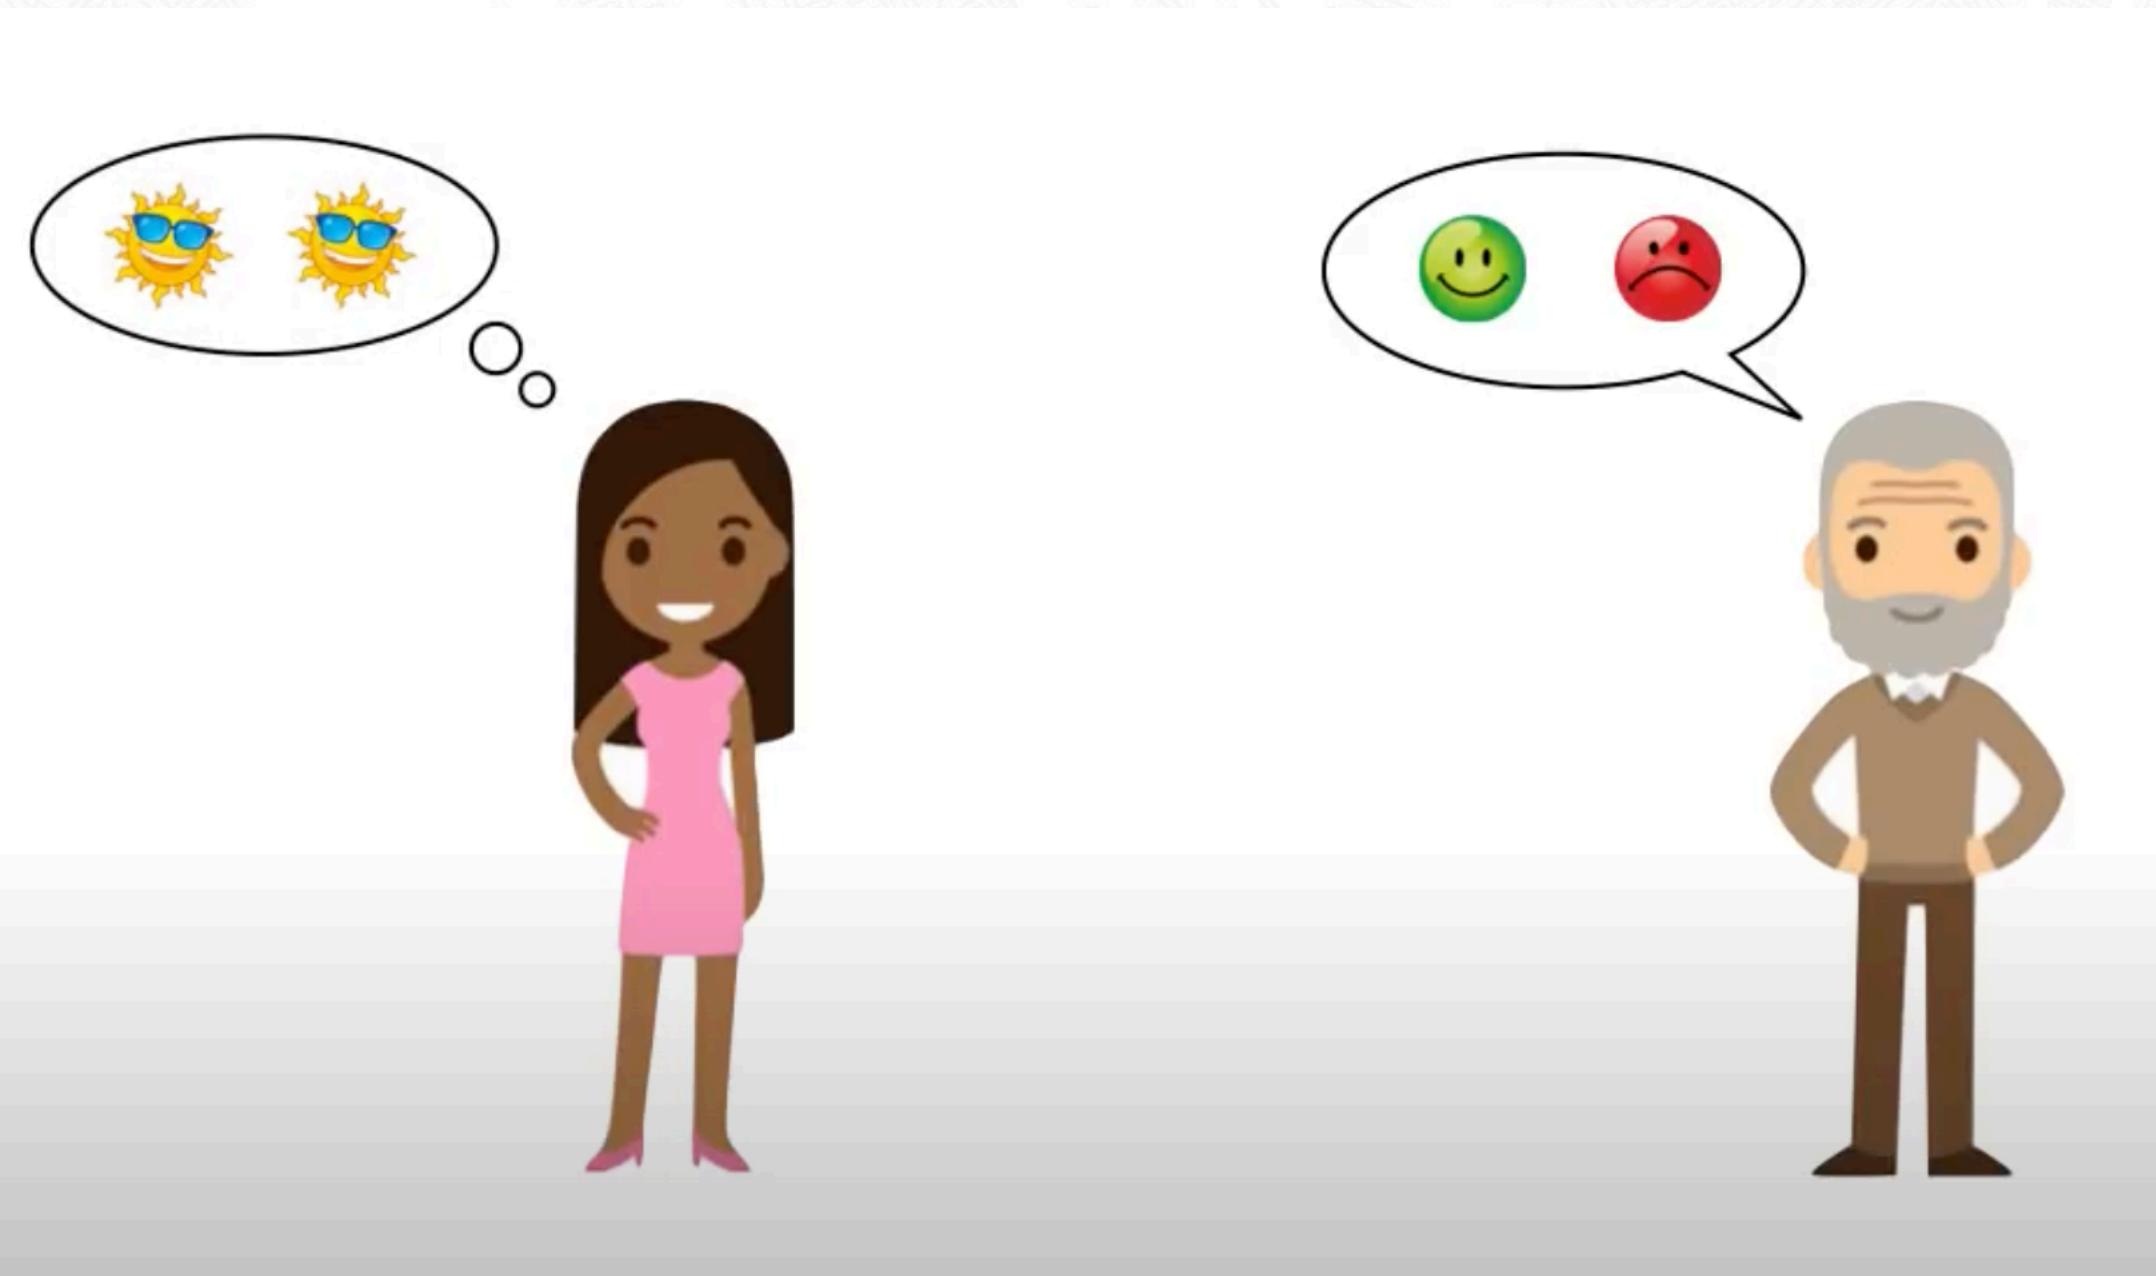
Al final se selecciona la secuencia que tiene una mayor probabilidad posterior. (Maximum Likelihood)



Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

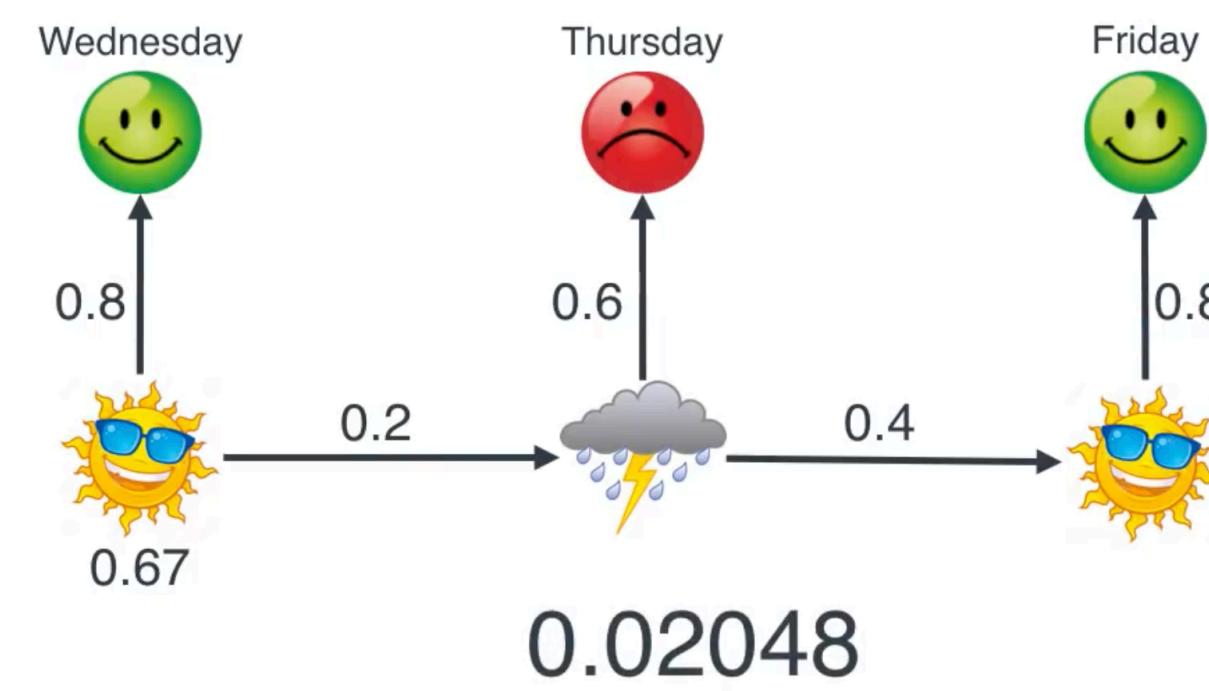
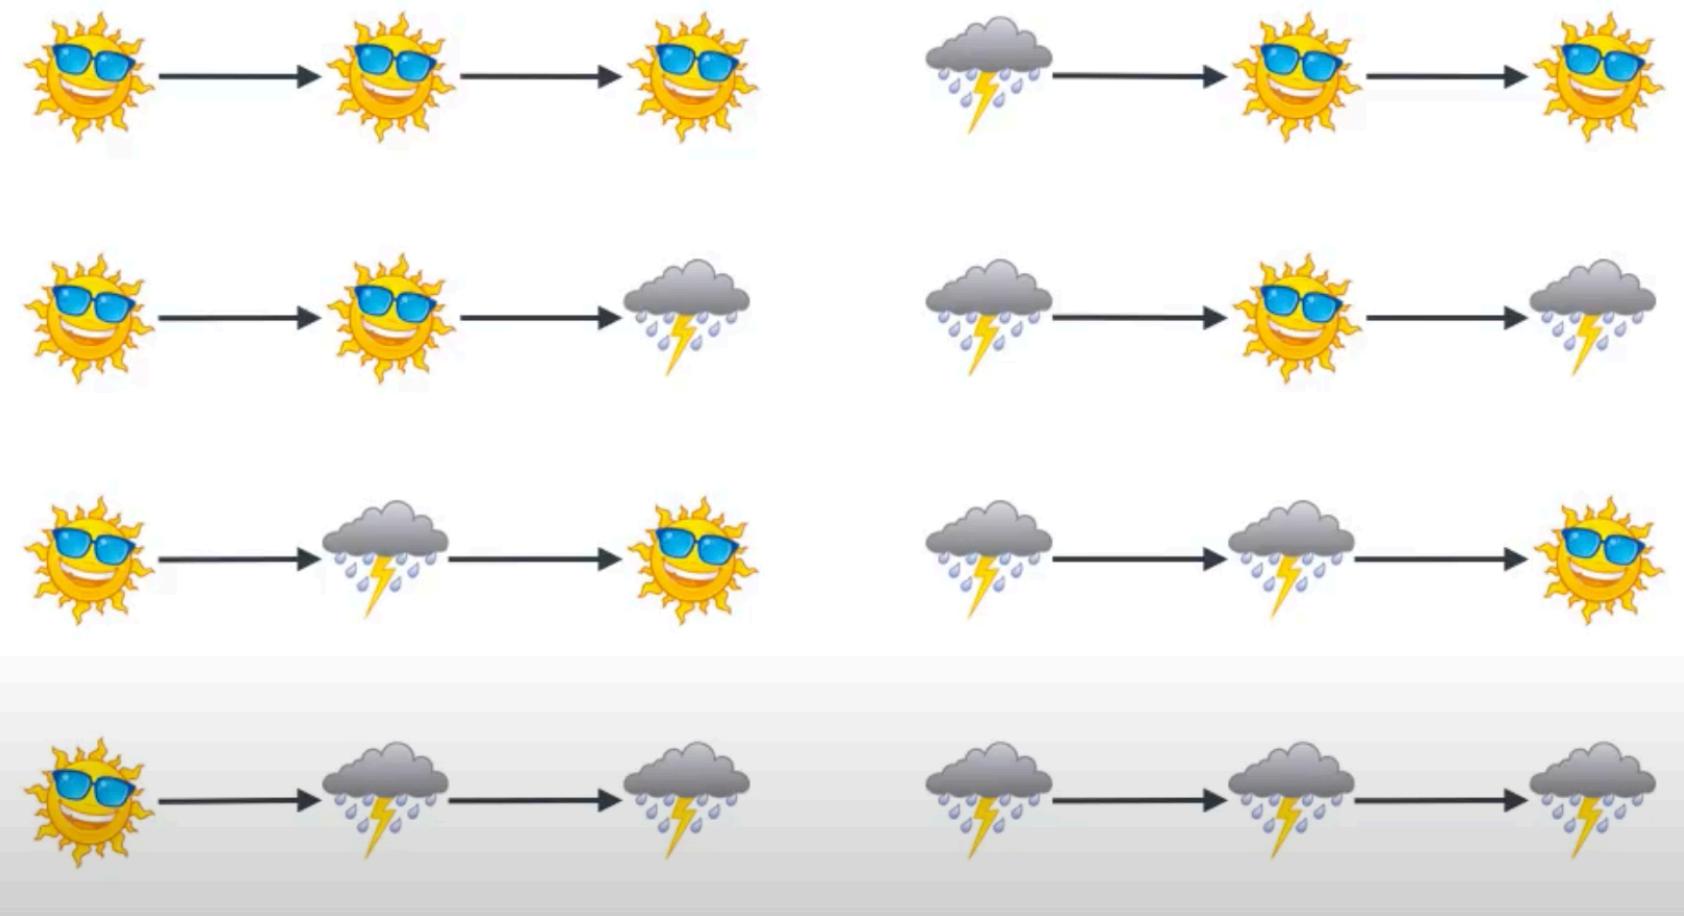
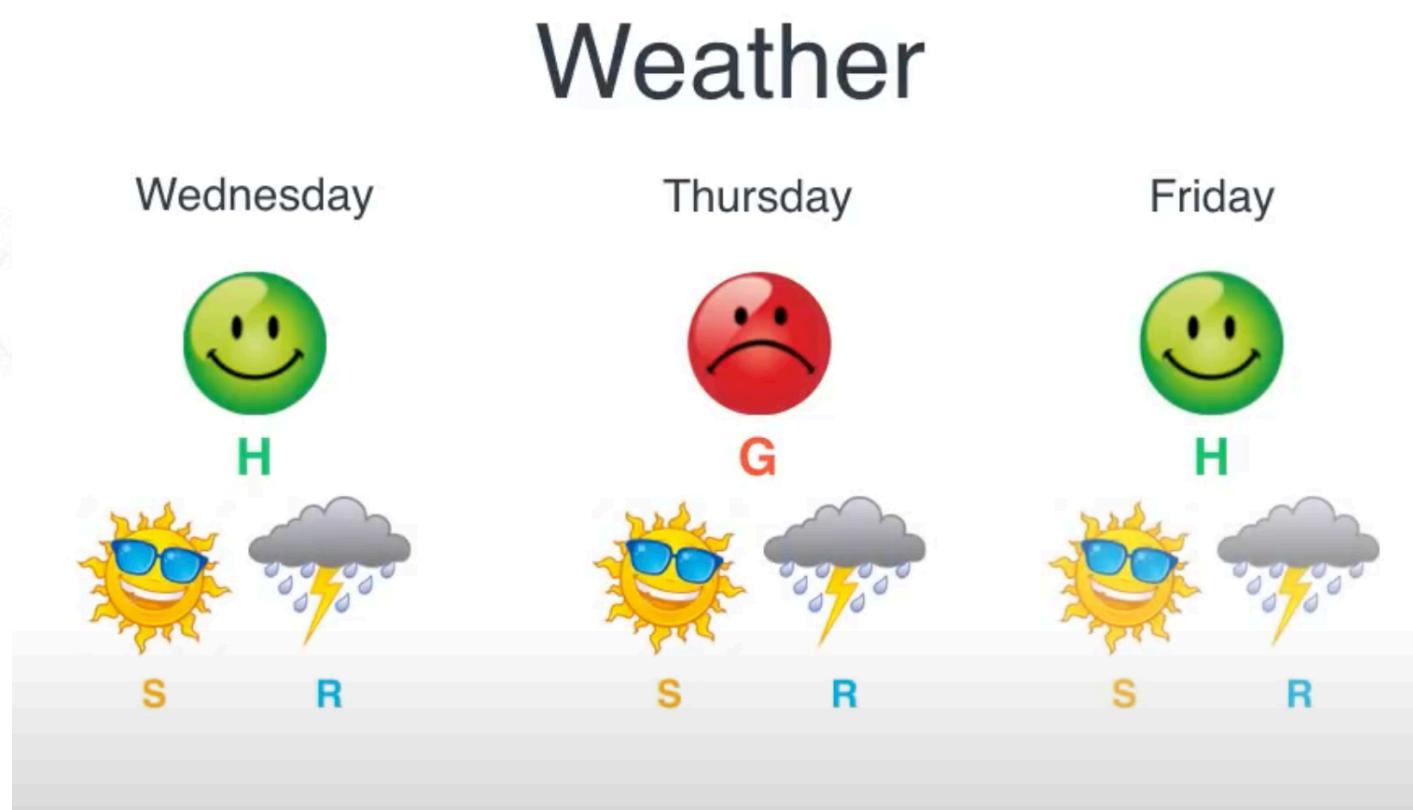
Por lo tanto, basado en la evidencia, y las observaciones del estado de animo de Bob, la secuencia de estados del clima más probable es que ambos días hayan sido soleados.



Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

¿Qué pasa si queremos saber cuál es la secuencia de estados del clima, dada 3 observaciones del estado de ánimo de Bob?

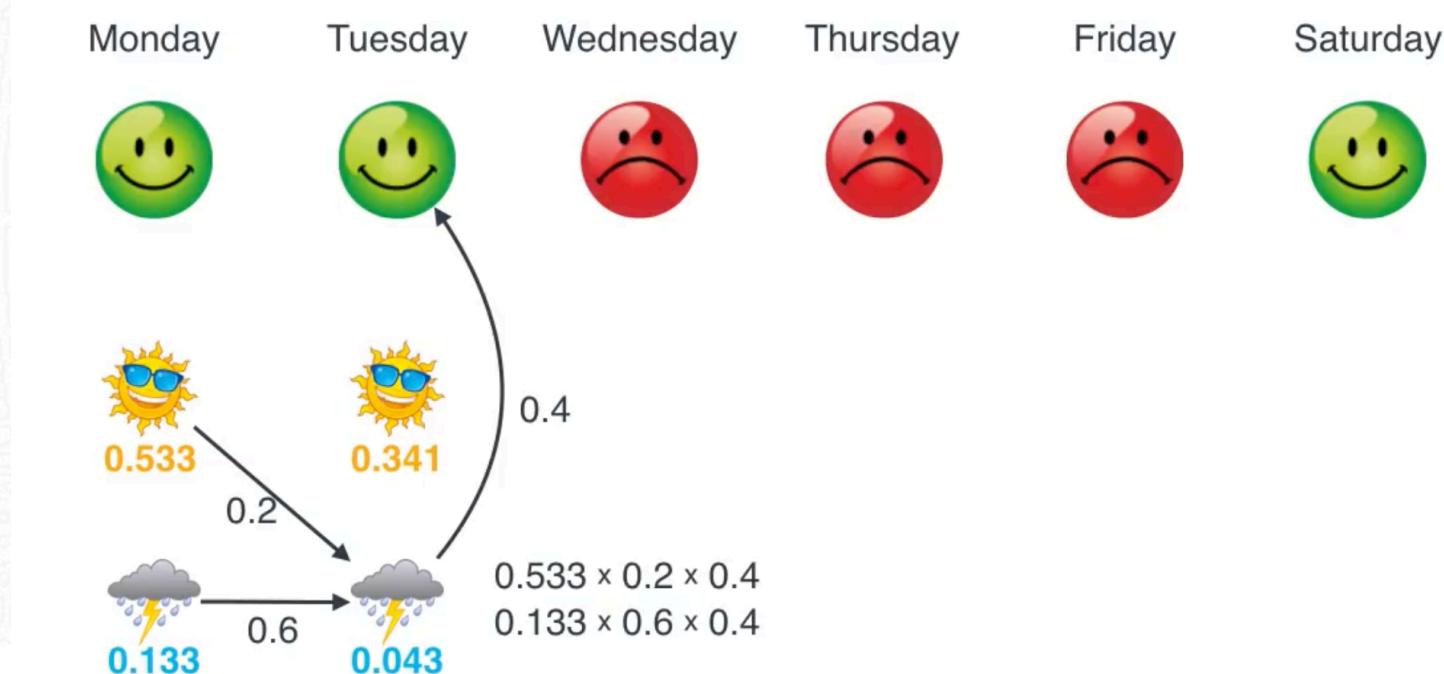
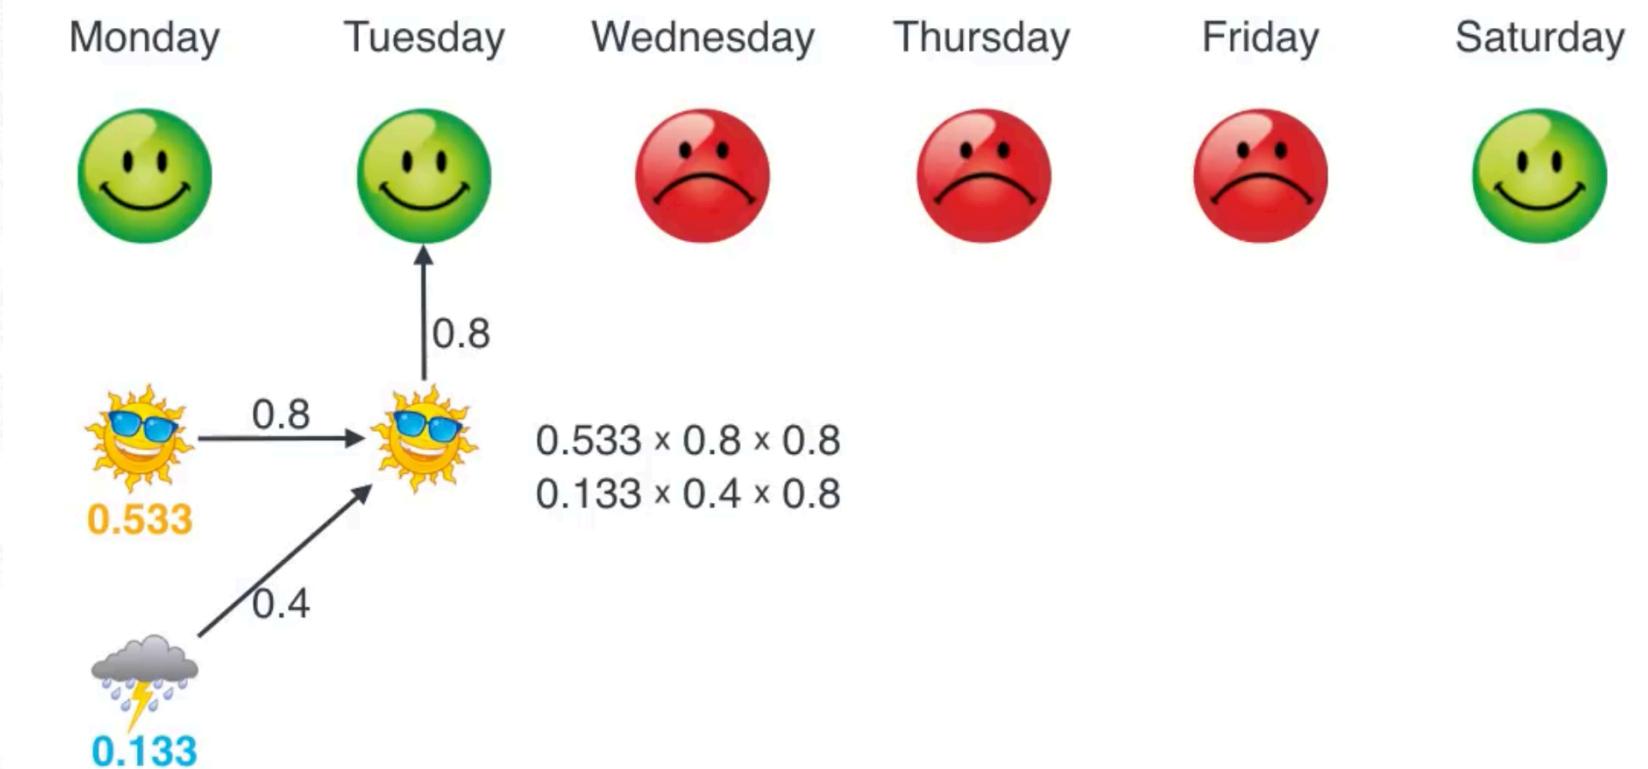
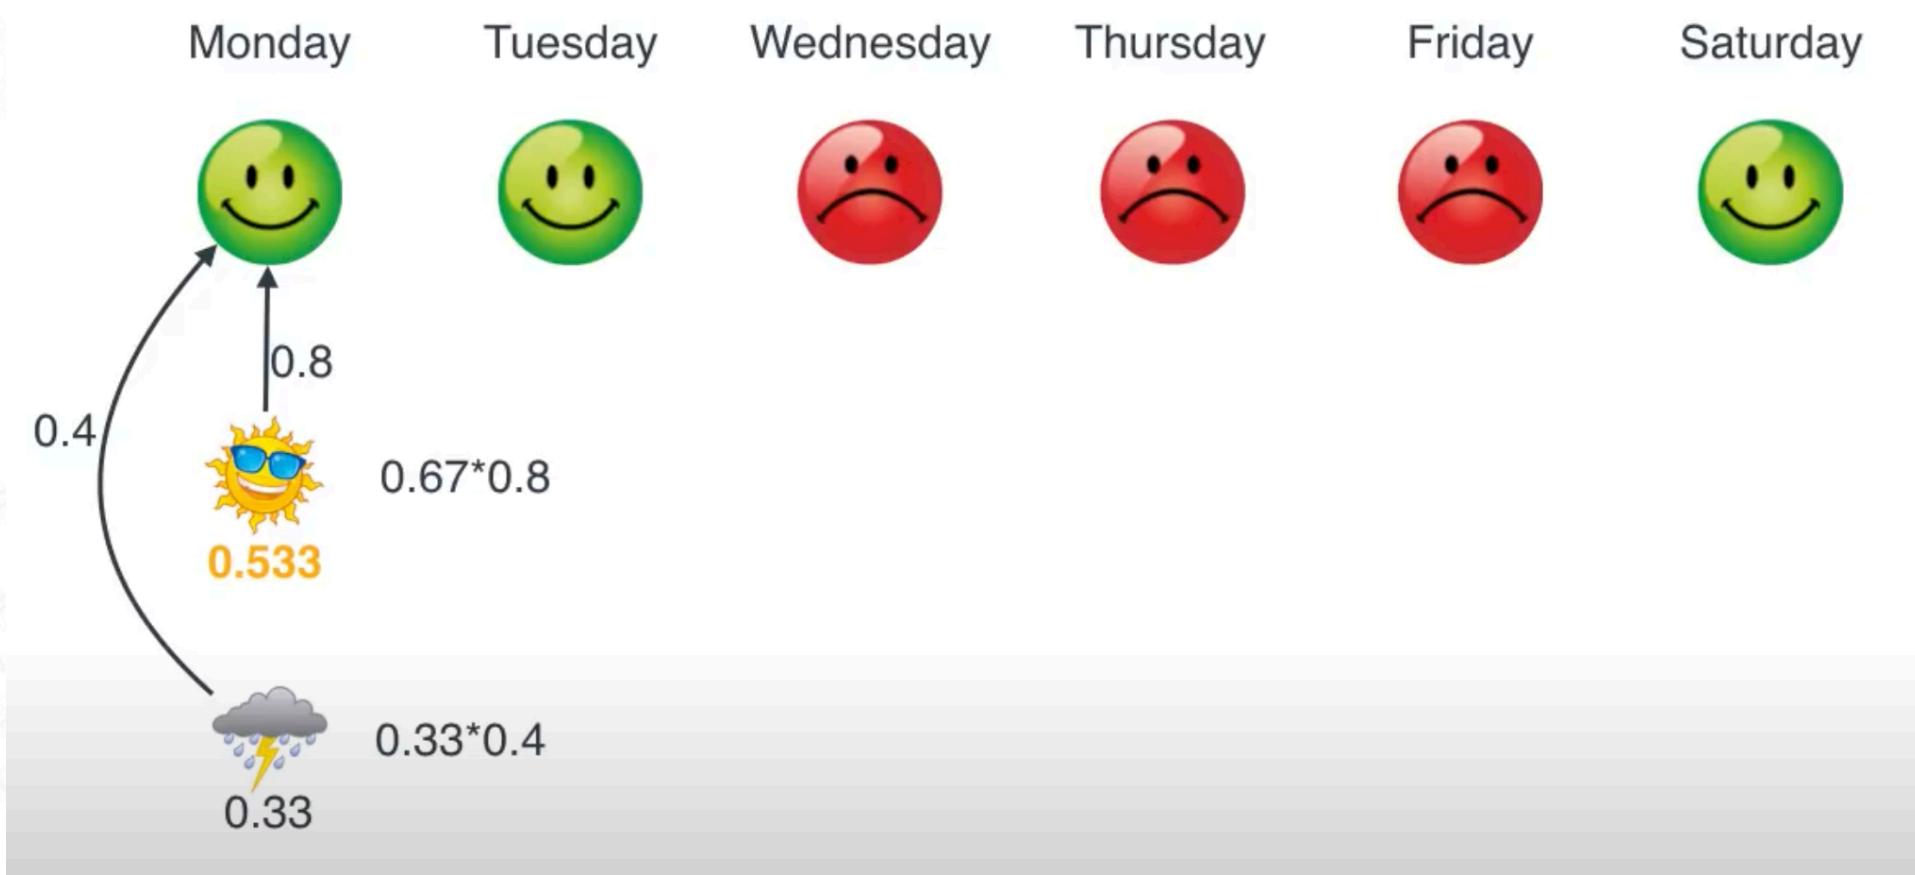


En este caso debemos evaluar 8 posibles combinaciones. El número de combinaciones a evaluar crece de forma exponencial.

Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

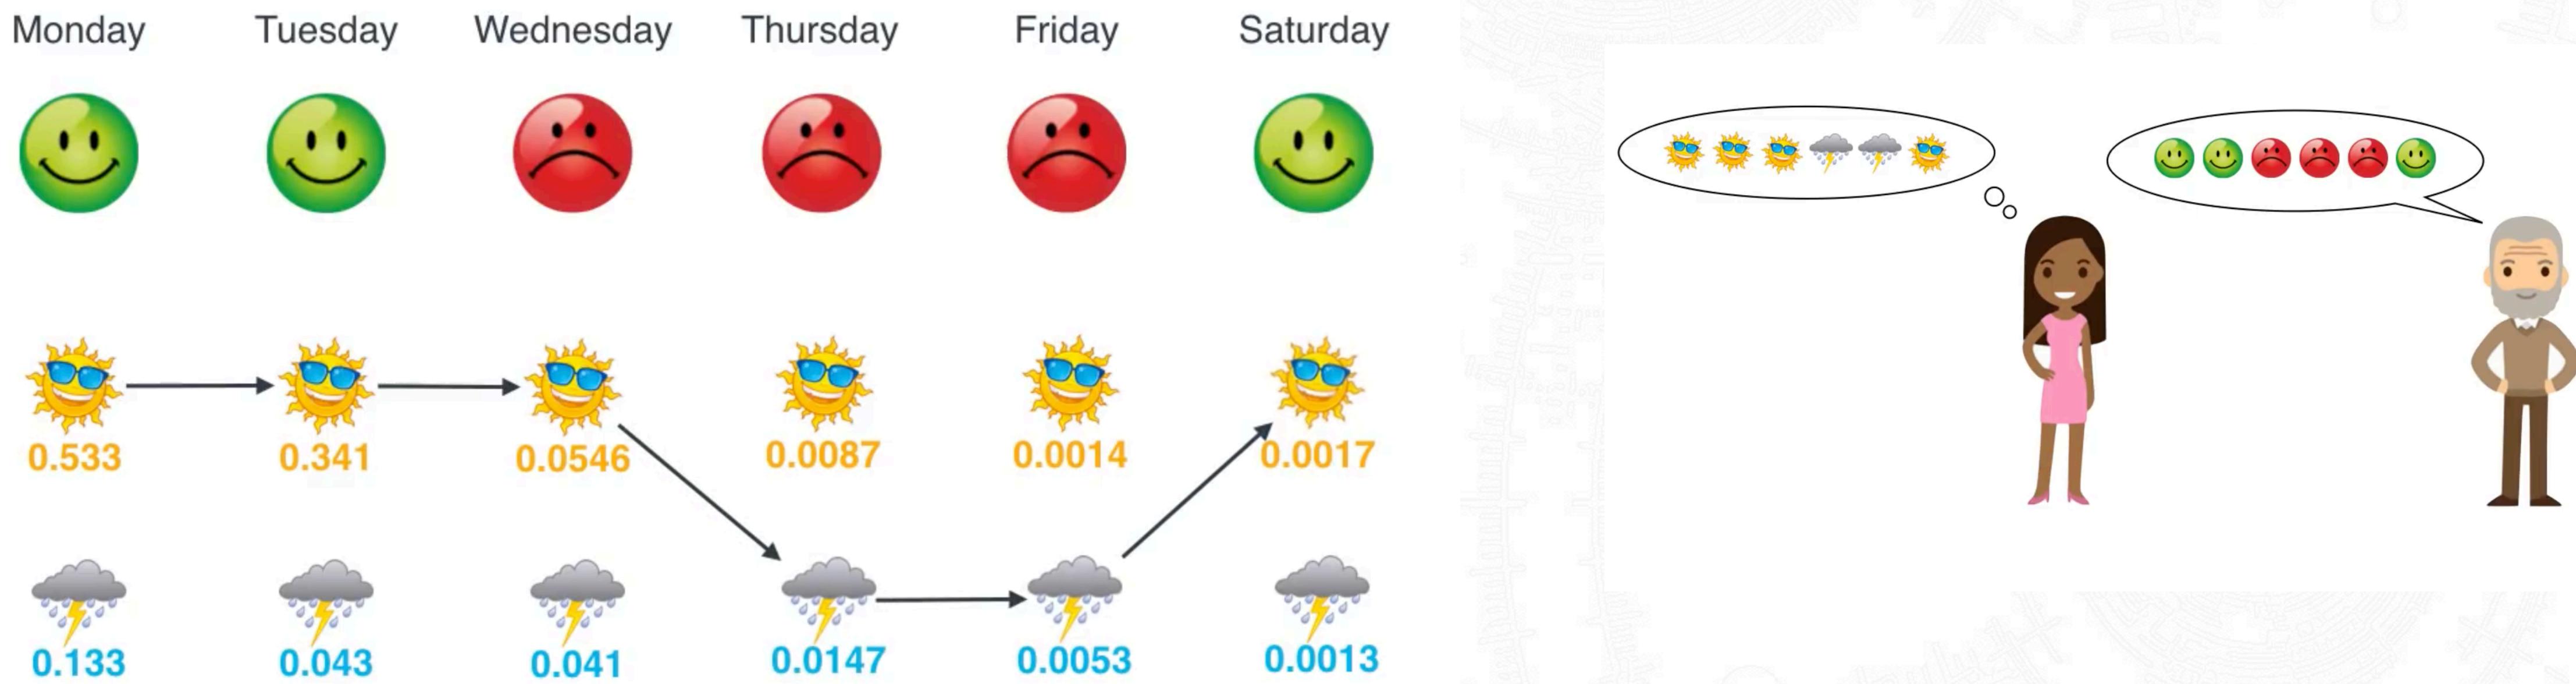
Para evitar realizar todas las posibles combinaciones, se utiliza el algoritmo **Viterbi**. Se empieza a calcular las probabilidades para cada estado, y solo se mantiene la mayor de las probabilidades en cada posición de la secuencia.



Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Ejemplo

Al final, para cada punto de la secuencia, se escoge el estado que tenga la mayor probabilidad posterior. De esa forma se puede encontrar la secuencia de estados del clima, más probable, que produjeron las observaciones del estado de ánimo de Bob.

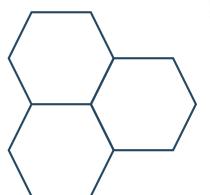
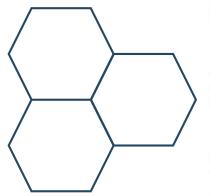


Source: <https://www.youtube.com/watch?v=kqSzLo9fenk>

# Contenido

HMM.

HMM para ASR systems.



# Hidden Markov Models

¿Pero cómo se aplica esto para Speech Recognition?

1. Suponga que  $N$  es el número de fonemas en el lenguaje.
2. Se modela las transiciones entre los fonemas (incluyendo el silencio) basado en datos escritos de entrenamiento.
3. Se tienen datos de pronunciación de los textos escritos, se realiza análisis mel-cepstral.
4. Se calcula la probabilidad que para un estado determinado (un fonema escrito) corresponda un vector mel-cepstral determinado.
5. Para un espectrograma determinado, se determina cual es la secuencia más probable que produzca este conjunto de observaciones. (Esto puede ser computacionalmente muy costoso).
6. Una vez se tienen las secuencias de fonemas, se busca en un diccionario las palabras correspondientes, y finalmente se pasa por un modelo de lenguaje.

# Hidden Markov Models

## Algoritmo Viterbi

### 1. Initialization

Set  $t = 2$ ;  
 $\delta_1(i) = \pi_i b_i(\mathbf{o}_1)$ ,  $1 \leq i \leq N$   
 $\psi_1(i) = 0$ ,  $1 \leq i \leq N$

### 2. Induction

$$\begin{aligned}\delta_t(j) &= b_j(\mathbf{o}_t) \max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}, \quad 1 \leq j \leq N \\ \psi_t(j) &= \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}], \quad 1 \leq j \leq N\end{aligned}$$

### 3. Update time

Set  $t = t + 1$ ;  
Return to step 2 if  $t \leq T$ ;  
Otherwise, terminate the algorithm (goto step 4).

### 4. Termination

$$\begin{aligned}P^* &= \max_{1 \leq i \leq N} [\delta_T(i)] \\ q_T^* &= \arg \max_{1 \leq i \leq N} [\delta_T(i)]\end{aligned}$$

### 5. Path (state sequence) backtracking

#### (a) Initialization

Set  $t = T - 1$

#### (b) Backtracking

$$q_t^* = \psi_{t+1}(q_{t+1}^*)$$

#### (c) Update time

Set  $t = t - 1$ ;  
Return to step (b) if  $t \geq 1$ ;  
Otherwise, terminate the algorithm.

Un problema es que se trabaja con producto de probabilidades, para evitar errores numéricos se puede trabajar con el logaritmo de estas probabilidades.

Source: <https://www.diva-portal.org/smash/get/diva2:831263/FULLTEXT01.pdf>



Gracias  
Preguntas?